

รายงานสรุปข้อสอบและเฉลยรายวิชาด้าน Data Science และ Machine Learning

Gemini CLI Autonomous Agent

26 เมษายน พ.ศ. 2569

1 Learn Python: Language Basics and Fundamental Data Processing

ข้อที่ 1

โจทย์: Dynamically-typed language หมายความว่าอะไร

ตัวเลือก:

- ประเภทของตัวแปรถูกตัดสินตอน Run-Time จึงไม่ต้องกำหนดประเภทของตัวแปรก่อนใช้งาน
- ประเภทของตัวแปรถูกตัดสินตอน Run-Time จึงต้องกำหนดประเภทของตัวแปรก่อนใช้งานเสมอ
- ประเภทของตัวแปรถูกตัดสินก่อน Run-Time จึงต้องกำหนดประเภทของตัวแปรก่อนใช้งานเสมอ
- ประเภทของตัวแปรถูกตัดสินก่อน Run-Time จึงไม่ต้องกำหนดประเภทของตัวแปรก่อนใช้งาน

คำตอบ: ประเภทของตัวแปรถูกตัดสินตอน Run-Time จึงไม่ต้องกำหนดประเภทของตัวแปรก่อนใช้งาน

คำอธิบาย: ภาษาโปรแกรมที่มีลักษณะเป็น Dynamically-typed คือภาษาที่ "ประเภทของข้อมูล" ของตัวแปรจะถูกผูกติดอยู่กับค่า (Value) ที่เก็บอยู่ในตัวแปรในขณะนั้น การตัดสินประเภทข้อมูลจะเกิดขึ้นในขณะที่โปรแกรมกำลังทำงาน (Run-time)

ข้อที่ 2

โจทย์: อะไรเป็นหัวใจหลักที่ทำให้ Jupyter notebook เข้าใจภาษาโปรแกรมภาษาต่าง ๆ

ตัวเลือก:

- Kernel
- Python
- Ipython
- ไฟล์ config

คำตอบ: Kernel

คำอธิบาย: สถาปัตยกรรมของ Jupyter แยกส่วนแสดงผล (Notebook) ออกจากส่วนประมวลผล (Kernel) การรองรับหลายภาษาทำได้โดยการติดตั้ง Kernel เฉพาะของภาษานั้นๆ

ข้อที่ 3

โจทย์: ถ้าสมุดโน้ต ณ ตอนนี้มี 5 cell และ cell ปัจจุบันอยู่ที่ cell รองสุดท้าย หลังจากที่เรา cell ปัจจุบันด้วยการกดปุ่ม Shift+Enter สมุดโน้ตจะมีกี่ cell

ตัวเลือก:

- 4
- 5
- 6
- 7

คำตอบ: 5 cell

คำอธิบาย: เมื่อเรา Cell รองสุดท้าย (ลำดับที่ 4 จาก 5) ด้วย Shift+Enter ระบบจะเลื่อน Focus ไปยัง Cell ถัดไป (ลำดับที่ 5) โดยไม่มีการสร้าง Cell ใหม่ จำนวน Cell รวมจึงยังคงเป็น 5

ข้อที่ 4

โจทย์: หากต้องการแสดง block ของโค้ดใน Markdown cell เราสามารถทำได้อย่างไร

ตัวเลือก:

- ใส่ space จำนวนเท่ากันแต่ต้องอย่างน้อย 4 ตัวในส่วนต้นของบรรทัดของโค้ดที่อยู่ใน Block เดียวกัน
- ใส่เครื่องหมาย - และตามด้วยเว้นวรรคในส่วนต้นของบรรทัดของโค้ดที่อยู่ใน Block เดียวกัน
- ใส่เครื่องหมาย * จำนวนเท่ากันในส่วนต้นของบรรทัดของโค้ดที่อยู่ใน Block เดียวกัน
- เราไม่สามารถแสดงโค้ดใน Markdown cell ได้

คำตอบ: ใส่ space จำนวนเท่ากันแต่ต้องอย่างน้อย 4 ตัวในส่วนต้นของบรรทัดของโค้ดที่อยู่ใน Block เดียวกัน

คำอธิบาย: การเว้นวรรค 4 ช่องหรือ 1 Tab เป็นมาตรฐานดั้งเดิม (Indented Code Block) ของ Markdown ในการสร้างส่วนแสดงผลโค้ด

ข้อที่ 5

โจทย์: ข้อใดเป็นผลลัพธ์ของโปรแกรมต่อไปนี้ ตัวเลือก:

- 2
- 2.0
- 4
- 4.0

```
1 x = 2
2 y = 4
3 y /= x
4 print(y)
```

คำตอบ: 2.0

คำอธิบาย: ตัวดำเนินการ / ใน Python 3 จะให้ผลลัพธ์เป็นทศนิยม (Float) เสมอ แม้การหารจะลงตัวก็ตาม

ข้อที่ 6

โจทย์: expression $4 + -1 * 4 / 2 ** 2$ มีค่าเท่ากับเท่าใด

ตัวเลือก:

- 0.0
- 3.0
- 36.0
- ไม่มีข้อถูก

คำตอบ: 3.0

คำอธิบาย: ลำดับความสำคัญเริ่มจากเลขยกกำลัง ($2 ** 2 = 4$) -> คูณ/หาร ($-1 * 4 / 4 = -1.0$) -> บวก ($4 + (-1.0) = 3.0$)

ข้อที่ 7

โจทย์: ให้ function funcA() มี definition ส่วนหัวเป็น funcA(*arg1 , arg2 = True) ในการเรียกใช้ funcA() จะต้องมีการใส่ argument จำนวนกี่ค่า

ตัวเลือก:

- 1 ค่า
- 2 ค่า
- อย่างน้อย 1 ค่า
- กี่ค่าก็ได้

คำตอบ: 0 ค่า

คำอธิบาย: เนื่องจาก *arg1 เป็นการรับ Argument แบบไม่จำกัดจำนวน (รวมถึง 0 ค่า) และ arg2 มีค่าเริ่มต้น (Default value) จึงสามารถเรียกใช้ฟังก์ชันโดยไม่ส่ง Argument ใดๆ ได้เลย

ข้อที่ 8

โจทย์: ข้อใดเกิด implicit data type conversion และผลลัพธ์มี data type ไต

ตัวเลือก:

- 4.0 + 4.0 ผลลัพธ์เป็น int
- 4.0 + 4.5 ผลลัพธ์เป็น float
- 3 + 4.0 ผลลัพธ์เป็น float
- 3 + 4.0 ผลลัพธ์เป็น int

คำตอบ: 3 + 4.0 ผลลัพธ์เป็น float

คำอธิบาย: เมื่อมีการดำเนินการระหว่าง Integer และ Float ระบบจะแปลง Integer เป็น Float โดยอัตโนมัติ (Type Promotion) เพื่อความแม่นยำ

ข้อที่ 9

โจทย์: ผลลัพธ์เมื่อรัน print(type("34" + 3)) คือข้อใด

ตัวเลือก:

- 343
- <class 'int'>
- <class 'str'>
- เกิด error

คำตอบ: เกิด error

คำอธิบาย: Python เป็น Strong Typing ไม่ยอมให้เชื่อม (Concatenate) String เข้ากับ Integer โดยตรง จะเกิด TypeError

ข้อที่ 10

โจทย์: หลังจากรันโปรแกรมต่อไปนี้ ค่า x จะมีค่าเท่ากับปริมาณใด ตัวเลือก:

- ค่า x ในบรรทัดแรกของโปรแกรม
- ผลรวมของจำนวนเต็มบวกทั้งหมดที่ไม่เกิน 1,000
- ผลรวมของจำนวนเต็มบวกเลขคู่ที่ไม่เกิน 1,000
- ผลรวมของจำนวนเต็มบวกเลขคี่ที่ไม่เกิน 1,000

```
1 x = 0
2 for i in range(1,1000,2):
3     if i%2 == 0:
4         x += i
```

คำตอบ: 0

คำอธิบาย: range(1, 1000, 2) ให้เลขทั้งหมด ซึ่งไม่มีทางที่ $i \% 2 == 0$ จะเป็นจริง เงื่อนไขการบวกจึงไม่เคยเกิดขึ้น ค่า x จึงยังคงเป็น 0

ข้อที่ 11

โจทย์: โปรแกรมต่อไปนี้ให้ผลลัพธ์อะไร ตัวเลือก:

- 3
- 4
- 250
- 500

```
1 x = 1
2 y = 1000
3 while x <= y:
4     if abs(x-y) > 500:
5         y = 100
6         continue
7     elif abs(x-y) > 10:
8         y = 5
9         continue
10    else:
11        y -= 1
12    x += 1
13 print(x)
```

คำตอบ: 4

คำอธิบาย: โปรแกรมวนลูปโดยปรับค่า y จาก 1000 -> 100 -> 5 จากนั้นจึงเข้าสู่เงื่อนไข else เพื่อเพิ่มค่า x จนกระทั่ง $x > y$ ผลสุดท้าย $x = 4$

ข้อที่ 12

โจทย์: ข้อใดถูกต้อง

ตัวเลือก:

- Python list เป็น immutable
- Python list มี items ที่เป็นข้อมูลประเภท list ปนกับข้อมูลประเภทอื่นได้
- ลำดับของ items ใน list ไม่สำคัญ
- Python list ไม่รองรับการทำ iteration

คำตอบ: Python list มี items ที่เป็นข้อมูลประเภท list ปนกับข้อมูลประเภทอื่นได้

คำอธิบาย: Python list เป็น Heterogeneous collection ที่สามารถเก็บข้อมูลต่างชนิดกันรวมถึง List ซ้อนกันได้

ข้อที่ 13

โจทย์: ข้อใดถูกต้องสำหรับ Python Set

ตัวเลือก:

- เป็น unordered data collection
- มี items ที่มีค่าซ้ำกันได้
- เป็น immutable data collection
- ถูกทุกข้อ

คำตอบ: เป็น unordered data collection

คำอธิบาย: Set ใน Python ไม่มีลำดับ (Unordered) และไม่สามารถเข้าถึงผ่าน Index ได้ รวมถึงเก็บค่าที่ไม่ซ้ำกันเท่านั้น

ข้อที่ 14

โจทย์: ข้อใดถูกต้อง ถ้ารันคำสั่ง t1 = tuple('1234')

ตัวเลือก:

- t1 จะมี item เดียว
- t1 จะมี length เท่ากับ 4 เนื่องจาก 'text' มีความยาว 4
- t1 จะมี 4 items ที่มีค่า 1, 2, 3 และ 4
- t1 จะมี 4 items ที่มีค่า '1', '2', '3' และ '4'

คำตอบ: t1 จะมี 4 items ที่มีค่า '1', '2', '3' และ '4'

คำอธิบาย: ฟังก์ชัน tuple() จะแตกสมาชิกจาก Iterable (ในที่นี้คือ String) ออกมาทีละตัวละสร้างเป็น Tuple

ข้อที่ 15

โจทย์: ให้ product เป็น dictionary ที่มีค่า 'id': 'P123', 'name': 'watch', 'price': 5000 ถ้าต้องการเพิ่ม 'color' เป็นอีก key หนึ่ง ที่มีค่า 'silver' ต้องเขียน code อย่างไร

ตัวเลือก:

- `product.add('color', 'silver')`
- `product.update('color', 'silver')`
- `product['color'] = 'silver'`
- ถูกทุกข้อ

คำตอบ: `product['color'] = 'silver'`

คำอธิบาย: การเพิ่มหรืออัปเดต Key ใน Dictionary ทำได้โดยการกำหนดค่าผ่านวงเล็บก้ามปูโดยตรง

ข้อที่ 16

โจทย์: ข้อใดไม่ใช่ประโยชน์ของ Functions

ตัวเลือก:

- Reuseability
- Modularity
- Availability
- Maintainability

คำตอบ: Availability

คำอธิบาย: Availability (ความพร้อมใช้งาน) เป็นคุณสมบัติของระบบงานในระดับโครงสร้างพื้นฐาน ไม่ใช่ประโยชน์โดยตรงจากการจัดโครงสร้างโค้ดด้วยฟังก์ชัน

ข้อที่ 17

โจทย์: จากฟังก์ชัน signature: `def create_customer(first_name, last_name, age, is_new_customer=True, **kwargs):`

ตัวเลือก:

- `create_customer('David', last_name='Berry', age=25, title='Mr.')`
- `create_customer('David', last_name='Berry', title='Mr.', occupation='programmer')`
- `create_customer('David', last_name='Berry', age=30, is_new_customer=False)`
- `create_customer('David', 'Berry', 30, False)`

ข้อใดทำให้เกิด error จากการเรียกใช้

คำตอบ: `create_customer('David', last_name='Berry', title='Mr.', occupation='programmer')`

คำอธิบาย: ขาด Argument ที่จำเป็น (Required Positional Argument) คือ `age`

ข้อที่ 18

โจทย์: ข้อใดคือประโยชน์ของการเปิดไฟล์ด้วย keyword with
ตัวเลือก:

- a. ไม่ต้องเรียกฟังก์ชัน file close() เพื่อปิดไฟล์ที่เปิดไว้ หลังจากออกจาก block ของ with แล้ว
- b. ใน block ของ with ฟังก์ชัน readline() จะวน loop อ่านทีละบรรทัดในไฟล์ ให้โดยอัตโนมัติ และเมื่ออ่านจนสุดไฟล์แล้ว ก็จะทำกา-
รออกจาก block ของ with โดยอัตโนมัติ
- ถูกทั้งข้อ a. และ b.
- ผิดทั้งข้อ a. และ b.

คำตอบ: ไม่ต้องเรียกฟังก์ชัน file close() เพื่อปิดไฟล์ที่เปิดไว้ หลังจากออกจาก block ของ with แล้ว

คำอธิบาย: with ทำหน้าที่เป็น Context Manager ที่จะเรียกใช้เมธอดปิดไฟล์ให้อัตโนมัติเมื่อออกจากบล็อก

ข้อที่ 19

โจทย์: โปรแกรมต่อไปนี้ให้ผลลัพธ์อะไร
ตัวเลือก:

- False
- (1,2,3,4)
- (1,2,3,4,6,9)
- [True, True, True, False]

```
1 coor = [ (1,2) , (2,4) , (3,6) , (4,9) ]  
2 print(list(map(lambda i: i[1]==2*i[0] , coor)))
```

คำตอบ: [True, True, True, False]

คำอธิบาย: ตรวจสอบว่าสมาชิกตัวที่ 2 ใน Tuple เท่ากับ 2 เท่าของตัวแรกหรือไม่ (1,2)->T, (2,4)->T, (3,6)->T, (4,9)->F

ข้อที่ 20

โจทย์: ข้อใดคือลำดับชั้น scope ของ modules ใน Python จากใหญ่ไปเล็กที่สุด
ตัวเลือก:

- Class -> Function -> Package
- Package -> Python File -> Function
- Package -> Class/Function -> Python File
- Function -> Class -> Variable

คำตอบ: Package -> Python File -> Function

คำอธิบาย: Package บรรจุหลายไฟล์ (Modules), ไฟล์บรรจุคลาสและฟังก์ชันตามลำดับโครงสร้าง

2 รู้จักคอมพิวเตอร์และระบบดิจิทัล

ข้อที่ 1

โจทย์: ตัวเลือกใดแสดงแนวคิดของการทำงานโดยคอมพิวเตอร์เชิงไฟฟ้า

ตัวเลือก:

- หลักการเปิด/ปิดสวิตช์ แทนค่า 0 หรือ 1 ในเลขฐานสอง
- หลักการทดเลขในระบบฐานสอง
- หลักการเหนี่ยวนำของแม่เหล็กไฟฟ้า
- หลักการต้านทานกระแสของไหลในตัวต้านทาน

คำตอบ: หลักการเปิด/ปิดสวิตช์ แทนค่า 0 หรือ 1 ในเลขฐานสอง

คำอธิบาย: ทรานซิสเตอร์ทำหน้าที่เป็นสวิตช์ที่มีสถานะ เปิด (1) และ ปิด (0) ซึ่งเป็นพื้นฐานของระบบดิจิทัล

ข้อที่ 2

โจทย์: ทรานซิสเตอร์ถูกใช้อย่างไรในระบบคอมพิวเตอร์

ตัวเลือก:

- ใช้แทนสวิตช์เชิงไฟฟ้า
- ใช้แทนสวิตช์เชิงกล
- ใช้แทนตัวต้านทานกระแส
- ใช้แทนตัวนำไฟฟ้าให้กระแสไหล

คำตอบ: ใช้แทนสวิตช์เชิงไฟฟ้า

คำอธิบาย: ทรานซิสเตอร์ทำหน้าที่ควบคุมการไหลของกระแสไฟฟ้าเพื่อแทนค่าทางตรรกศาสตร์ (Boolean Logic)

ข้อที่ 3

โจทย์: กำหนดข้อมูลเลขฐานสอง ขนาด 8 หลักเป็น 10010000 ข้อใดถูกต้อง

ตัวเลือก:

- หากกำหนดให้บิตแรกสุดท้ายซ้ายเป็นเครื่องหมาย โดย 1 แทนค่าลบ และ 0 แทนค่าบวก เลขนี้จำเป็นจำนวนลบ
- หากไม่มีการเก็บเครื่องหมาย เลขนี้จะแทนค่า 144 ในฐานสิบ
- เลข 8 หลักสามารถแทนค่าได้ทั้งหมด 256 รูปแบบ ซึ่งเป็นจำนวนบวกทั้งหมด หรือมีทั้งบวกและลบก็ได้
- ถูกทุกตัวเลือก

คำตอบ: ถูกทุกตัวเลือก

คำอธิบาย: (1) บิตซ้ายสุดเป็น 1 คือค่าลบ (2) ไม่คิดเครื่องหมายได้ 144 (3) 8 บิตแทนได้ 256 รูปแบบ

ข้อที่ 4

โจทย์: หากกำหนด $A = 0$ และ $B = 1$ ตัวเลือกใดเป็นผลลัพธ์ของวงจรต่อไปนี้
ตัวเลือก:

- 0
- 1
- 0 หรือ 1 ก็ได้
- 2

ลักษณะรูปภาพ: ภาพแสดงวงจรลอจิกเกตที่ประกอบด้วย AND gate และ NOT gate ต่อร่วมกัน โดยรับอินพุต A และ B ผ่านเกตต่างๆ จนถึงเอาต์พุตสุดท้าย

คำตอบ: 1

คำอธิบาย: จากการใส่ลอจิก: $\text{NOT}(A \text{ AND } A) = 1$, $\text{NOT}(B \text{ AND } B) = 0$, $(1 \text{ AND } 0) = 0$, และ NOT ตัวสุดท้ายกลับค่า 0 เป็น 1

ข้อที่ 5

โจทย์: หากกำหนด $A = 0100$ และ $B = 0010$ ตัวเลือกใดเป็นผลลัพธ์ของ $A \text{ AND } B$
ตัวเลือก:

- 0000
- 0110
- 1000
- 1001

คำตอบ: 0000

คำอธิบาย: การทำ Bitwise AND ที่ละตำแหน่ง: $(0\&0)$, $(1\&0)$, $(0\&1)$, $(0\&0)$ ผลรวมเป็น 0000

ข้อที่ 6

โจทย์: จากตัวเลือกต่อไปนี้ หน่วยความจำแบบใดทำงานได้เร็วที่สุด
ตัวเลือก:

- HDD
- ROM
- RAM
- CPU

คำตอบ: CPU (Register)

คำอธิบาย: Register อยู่ภายใน CPU โดยตรง มีความเร็วสูงที่สุดเนื่องจากไม่มีความหน่วงจากการรับส่งผ่านบัสภายนอก

ข้อที่ 7

โจทย์: ตัวเลือกใดเป็นส่วนคำนวณของคอมพิวเตอร์

ตัวเลือก:

- HDD
- SSD
- RAM
- CPU

คำตอบ: CPU

คำอธิบาย: CPU (Central Processing Unit) มีหน่วย ALU ที่ทำหน้าที่คำนวณทางคณิตศาสตร์และตรรกศาสตร์

ข้อที่ 8

โจทย์: การทำงานร่วมกันของอุปกรณ์ฮาร์ดแวร์ต่างๆ เกิดขึ้นได้อย่างไร

ตัวเลือก:

- โปรแกรมคอมพิวเตอร์มีหน้าที่ควบคุมและประสานงานการทำงานส่วนต่างๆ
- หน่วยประมวลผลกลางรับคำสั่งและประมวลผลเป็นสัญญาณควบคุมการทำงานส่วนต่างๆ
- ระบบปฏิบัติการดำเนินการควบคุมและประสานงานการทำงานส่วนต่างๆ
- ผู้ควบคุมระบบคอมพิวเตอร์ดำเนินการควบคุมการทำงานของฮาร์ดแวร์ส่วนต่างๆ

คำตอบ: ระบบปฏิบัติการดำเนินการควบคุมและประสานงานการทำงานส่วนต่างๆ

คำอธิบาย: OS ทำหน้าที่เป็นตัวกลางบริหารจัดการทรัพยากร (CPU, RAM, Storage) ให้ทำงานสอดคล้องประสานกัน

ข้อที่ 9

โจทย์: ภาษาแอสเซมบลีคืออะไร

ตัวเลือก:

- ภาษาโปรแกรมซึ่งเทียบเท่ากับภาษาเครื่อง แต่เขียนให้อยู่ในรูปแบบที่อ่านได้ง่ายขึ้น
- ภาษาโปรแกรมระดับสูง มีโครงสร้างรองรับการทำงานที่หลากหลาย
- ภาษาโปรแกรมกลางที่สามารถทำงานได้กับคอมพิวเตอร์หลายชนิด
- ภาษาที่ใช้ในการกำหนดรูปแบบการทำงานร่วมกันของอุปกรณ์ในระบบคอมพิวเตอร์

คำตอบ: ภาษาโปรแกรมซึ่งเทียบเท่ากับภาษาเครื่อง แต่เขียนให้อยู่ในรูปแบบที่อ่านได้ง่ายขึ้น

คำอธิบาย: เป็นภาษาระดับต่ำที่ใช้ตัวอักษรย่อ (Mnemonics) แทนรหัสเลขฐานสองของภาษาเครื่อง

ข้อที่ 10

โจทย์: การมี core หรือแกนประมวลผล มากขึ้น มีประโยชน์อย่างไร

ตัวเลือก:

- สามารถประมวลผลหลายๆ งานพร้อมกันโดยกระจายไปทำงานตามแกนต่างๆ กันได้
- สามารถแบ่งงานเป็นส่วนย่อยๆ ไปทำงานตามแกนต่างๆ ทำให้งานโดยรวมเสร็จเร็วขึ้น
- สามารถแบ่งให้ผู้ใช้งานหลายๆ คนเข้ามาใช้งานพร้อมกันได้ โดยแบ่งแกนประมวลผลกันไปใช้
- ถูกทุกตัวเลือก

คำตอบ: ถูกทุกตัวเลือก

คำอธิบาย: ช่วยในการทำ Multitasking, ขบวนการประมวลผล (Parallelism) และรองรับผู้ใช้ได้มากขึ้น

ข้อที่ 11

โจทย์: ตัวเลือกใดเป็นหน้าที่ของระบบปฏิบัติการ

ตัวเลือก:

- จัดสรรทรัพยากรในระบบคอมพิวเตอร์ให้ซอฟต์แวร์ต่างๆ
- ควบคุมสิทธิการใช้งานของผู้ใช้ในการเข้าถึงทรัพยากรต่างๆ
- ติดต่อกับฮาร์ดแวร์คอมพิวเตอร์
- ถูกทุกตัวเลือก

คำตอบ: ถูกทุกตัวเลือก

คำอธิบาย: ครอบคลุมการจัดสรรทรัพยากร, การควบคุมสิทธิการใช้งาน และการจัดการระบบเครือข่าย

ข้อที่ 12

โจทย์: เหตุใดไฟล์ภาพ JPG จากมือถือจึงเปิดบนคอมพิวเตอร์ได้แม้สถาปัตยกรรมต่างกัน

ตัวเลือก:

- เพราะใช้โปรแกรมเดียวกันในการอ่านไฟล์
- เพราะโปรแกรมอ่านไฟล์สามารถทำงานได้ในทุกระบบปฏิบัติการ
- เพราะโปรแกรมอ่านไฟล์เข้าใจข้อตกลงการแทนข้อมูลของไฟล์
- เพราะโปรแกรมอ่านไฟล์ทำงานได้ในทุกสถาปัตยกรรม

คำตอบ: เพราะโปรแกรมอ่านไฟล์เข้าใจข้อตกลงการแทนข้อมูลของไฟล์

คำอธิบาย: เกิดจากมาตรฐานรูปแบบไฟล์ (File Format Standards) ที่เป็นข้อตกลงร่วมกันในการเก็บข้อมูล

ข้อที่ 13

โจทย์: ตัวเลือกใดถูกต้องเกี่ยวกับการเก็บข้อมูลภาพ

ตัวเลือก:

- การเก็บข้อมูลสีของภาพสีเป็นการเก็บข้อมูลองค์ประกอบของสีที่ทำให้เกิดสีนั้นๆ ขึ้น
- การเก็บข้อมูลภาพทำได้โดยแบ่งภาพเป็นจุดเล็กๆ และเก็บสีของแต่ละจุดนั้น
- การเก็บข้อความภาพสามารถทำได้โดยเก็บข้อมูลสมการที่ใช้ในการวาดเส้นให้เกิดภาพนั้น
- ถูกทุกตัวเลือก

คำตอบ: ถูกทุกตัวเลือก

คำอธิบาย: ครอบคลุมทั้งการเก็บองค์ประกอบสี (RGB), การแบ่งเป็นจุด (Bitmap/Pixel) และการใช้สมการ (Vector)

ข้อที่ 14

โจทย์: หากข้อมูลทุกรูปแบบเก็บเป็นเลขฐานสอง ข้อใดถูกต้อง

ตัวเลือก:

- เราสามารถเปิดไฟล์ข้อความ โดยมองเป็นรูปภาพแบบ แต่น่าจะเป็นรูปที่ดูไม่รู้เรื่อง
- เราสามารถมองไฟล์รูปภาพเป็นชุดของตัวเลข สามารถนำมาบวกลบได้
- เราสามารถมองไฟล์วิดีโอเป็นไฟล์ข้อความขนาดใหญ่ได้ แต่น่าจะอ่านไม่ออก
- ถูกทุกตัวเลือก

คำตอบ: ถูกทุกตัวเลือก

คำอธิบาย: ข้อมูลดิจิทัลคือชุดตัวเลข ความหมายขึ้นอยู่กับวิธีการตีความของโปรแกรมที่นำไปเปิด

ข้อที่ 15

โจทย์: หากกำหนด $A = 0$ และ $B = 1$ ตัวเลือกใดเป็นผลลัพธ์ของวงจรต่อไปนี้

ตัวเลือก:

- 0
- 1
- 0 หรือ 1 ก็ได้
- 2

ลักษณะรูปภาพ: ภาพแสดงสัญลักษณ์ของ XOR Gate (Exclusive OR Gate) ที่รับอินพุต A และ B

คำตอบ: 1

คำอธิบาย: XOR Gate จะให้ผลลัพธ์เป็น 1 เมื่ออินพุตต่างกัน (0 และ 1)

3 รู้จักปัญญาประดิษฐ์ และการเรียนรู้ของเครื่อง

ข้อที่ 1

โจทย์: ข้อใดเป็นคำที่ตีความได้แตกต่างกันมากที่สุดในคำนิยามของปัญญาประดิษฐ์

ตัวเลือก:

- เวลา
- มนุษย์
- ความฉลาด
- เครื่องคอมพิวเตอร์

คำตอบ: ความฉลาด

คำอธิบาย: "ความฉลาด" เป็นนามธรรมที่ไม่มีนิยามสากลและการตีความหลากหลายในเชิงจิตวิทยาและวิทยาการคอมพิวเตอร์

ข้อที่ 2

โจทย์: การทดสอบทัวริง (Turing Test) เกี่ยวข้องกับข้อใดมากที่สุด

ตัวเลือก:

- ภาษาจีน
- การเรียนรู้แบบเสริมแรง
- การรู้จำรูปภาพตัวอักษร
- การเลียนแบบมนุษย์ด้านการสื่อสาร

คำตอบ: การเลียนแบบมนุษย์ด้านการสื่อสาร

คำอธิบาย: เป็นการทดสอบความสามารถของเครื่องจักรในการสื่อสารผ่านตัวอักษรให้แนบเนียนจนมนุษย์แยกไม่ออก

ข้อที่ 3

โจทย์: ข้อใดเปรียบของระบบปัญญาประดิษฐ์ที่มีมากกว่ามนุษย์คือข้อใด

ตัวเลือก:

- เข้าใจมนุษย์ได้มากกว่ามนุษย์ด้วยกัน
- คำนวณทางคณิตศาสตร์ได้ดีกว่ามนุษย์
- ค้นหาคำตอบได้หลากหลายรูปแบบมากกว่ามนุษย์
- เข้าใจภาพและเสียงด้วยรายละเอียดที่มากกว่ามนุษย์

คำตอบ: คำนวณทางคณิตศาสตร์ได้ดีกว่ามนุษย์

คำอธิบาย: คอมพิวเตอร์ประมวลผลตัวเลขมหาศาลได้แม่นยำและรวดเร็วกว่ามนุษย์ที่จำกัดด้วยความเหนื่อยล้า

ข้อที่ 4

โจทย์: ข้อใดไม่ใช่ตัวอย่างของการประยุกต์ใช้งานทางปัญญาประดิษฐ์
ตัวเลือก:

- การตอบโต้ผ่านแชทบอต
- การค้นหารูปภาพด้วยการใช้รูปภาพ
- การค้นหาประวัติค้นไข์จากรหัสแท่ง
- การค้นหาเส้นทางที่เร็วที่สุดในการเดินทางด้วยรถยนต์

คำตอบ: การค้นหาประวัติค้นไข์จากรหัสแท่ง (Barcode)

คำอธิบาย: การสแกนบาร์โค้ดเป็นการเข้าถึงข้อมูลจากฐานข้อมูลโดยตรง ไม่มีการเรียนรู้หรือการตัดสินใจที่ซับซ้อนแบบ AI

ข้อที่ 5

โจทย์: การหาวิธีการเลื่อนแผ่นในเกม 8-Puzzle ไม่เกี่ยวข้องกับข้อใด
ตัวเลือก:

- การเข้าใจภาษาธรรมชาติ
- การกำหนดสถานะของปัญหา
- การใช้เหตุผลด้วยวิธีการตรรกศาสตร์
- การค้นหาในปริภูมิของปัญหา (State Space)

คำตอบ: การเข้าใจภาษาธรรมชาติ

คำอธิบาย: เกม 8-Puzzle แก้ไขด้วยตรรกศาสตร์และการค้นหาในพื้นที่สถานะ (State Space) ไม่เกี่ยวกับการประมวลผลภาษา

ข้อที่ 6

โจทย์: ข้อใดคือปัญหาของการใช้การค้นหาแบบ Depth First Search (DFS)
ตัวเลือก:

- เวลาที่ใช้ค้นหา
- หน่วยความจำที่ต้องใช้
- สถานะของคำตอบที่ใกล้เคียงกันกับสถานะเดิมมากเกินไป
- วิธีการยุ่งยากที่ใช้ประเมินความดีของคำตอบในขณะที่ค้นหา

คำตอบ: หน่วยความจำที่ต้องใช้

คำอธิบาย: DFS ต้องเก็บเส้นทางใน Stack หากกราฟลึกมากอาจเกิดปัญหานหน่วยความจำเต็มหรือ Stack Overflow

ข้อที่ 7

โจทย์: ข้อใดเป็นข้อดีของการใช้ต้นไม้ตัดสินใจ (Decision Tree)

ตัวเลือก:

- ทำงานกับข้อมูลที่เป็นตัวเลขได้ดี
- มนุษย์สามารถเข้าใจผลลัพธ์จากโมเดลได้ง่ายกว่าการเรียนรู้ในแบบอื่น ๆ
- ทนต่อข้อมูลที่มีสัญญาณรบกวนเนื่องจากใช้ข้อมูลปริมาณมากและวิธีการทางสถิติ
- ทำงานใกล้เคียงกับมนุษย์ เนื่องจากเป็นการจำลองเซลล์ประสาทของมนุษย์

คำตอบ: มนุษย์สามารถเข้าใจผลลัพธ์จากโมเดลได้ง่ายกว่าการเรียนรู้ในแบบอื่น ๆ

คำอธิบาย: เป็นโมเดลแบบกล่องขาว (White-box) ที่แสดงขั้นตอนการตัดสินใจในรูปแบบ Flowchart ที่มนุษย์อ่านได้

ข้อที่ 8

โจทย์: ในการจำแนกรูปภาพ นิยมใช้การเรียนรู้แบบใด

ตัวเลือก:

- ทฤษฎีของเบย์ (Bayes' Theorem)
- นิวรอลเน็ตเวิร์กแบบคอนโวลูชัน (Convolution Neural Network)
- ต้นไม้ตัดสินใจ (Decision Tree)
- การวิเคราะห์การถดถอยเชิงเส้น (Linear Regression)

คำตอบ: นิวรอลเน็ตเวิร์กแบบคอนโวลูชัน (Convolutional Neural Network - CNN)

คำอธิบาย: CNN ถูกออกแบบมาเพื่อตรวจจับคุณลักษณะเชิงพื้นที่ (Spatial Features) ในรูปภาพได้โดยอัตโนมัติ

ข้อที่ 9

โจทย์: ข้อใดคือหัวใจสำคัญของกระบวนการการเรียนรู้ของเครื่อง

ตัวเลือก:

- ลดข้อผิดพลาด (Error) บนตัวอย่างที่ใช้เรียนรู้
- สร้างตัวอย่างใหม่ เพื่อให้ครอบคลุมตัวอย่างใหม่ในทุก ๆ กรณี
- ใช้ตัวอย่างทดสอบ (Test data) เพื่อทำให้ความถูกต้องของโมเดลสูงที่สุด
- ต้องมีระบบที่แก้ไขข้อผิดพลาดหลังจากได้ผลลัพธ์จากโมเดลแล้วในทุก ๆ ครั้ง

คำตอบ: ลดข้อผิดพลาด (Error) บนตัวอย่างที่ใช้เรียนรู้

คำอธิบาย: การเรียนรู้คือการปรับพารามิเตอร์เพื่อให้ความแตกต่างระหว่างค่าทำนายและค่าจริง (Loss/Error) ต่ำที่สุด

ข้อที่ 10

โจทย์: อัลกอริทึมใดเหมาะกับการพยากรณ์แนวโน้มค่าต่อเนื่อง เช่น ราคาหุ้น
ตัวเลือก:

- ต้นไม้ตัดสินใจ
- ทฤษฎีของเบย์ส์
- การวิเคราะห์การถดถอยเชิงเส้น
- นิวรอลเน็ตเวิร์กแบบคอนโวลูชัน

คำตอบ: การวิเคราะห์การถดถอยเชิงเส้น (Linear Regression)

คำอธิบาย: Regression ออกแบบมาเพื่อทำนายค่าตัวเลขต่อเนื่องและระบุทิศทางความสัมพันธ์ของข้อมูล

4 Machine Learning Series: Supervised Learning

ข้อที่ 1

โจทย์: ข้อใดกล่าวผิดเกี่ยวกับ Loss function

ตัวเลือก:

- Mean squared error เป็น Loss function ประเภทหนึ่งที่ใช้ใน regression
- เป็น Function ที่วัดค่าความแตกต่างของสิ่งที่โมเดลทำนายกับค่าจริง
- ค่า Loss เยอะๆ ยิ่งดี
- เป็น Function ที่ Learning algorithm ใช้สำหรับ Minimise

คำตอบ: ค่า Loss เยอะๆ ยิ่งดี

คำอธิบาย: Loss Function วัดความผิดพลาด เป้าหมายคือการทำให้นี้เหลือน้อยที่สุดเพื่อให้โมเดลแม่นยำที่สุด

ข้อที่ 2

โจทย์: ข้อใดกล่าวผิดเกี่ยวกับ Hyper-parameters

ตัวเลือก:

- เป็นค่าที่มีการเปลี่ยนแปลงด้วย Learning algorithm
- เป็นค่าที่ถูกกำหนดก่อนการเทรนโมเดล
- เป็นค่าที่ควบคุมการหาค่า Model parameters ให้ตรงกับความต้องการ
- สามารถหาค่าที่เหมาะสมได้จากการวัดประสิทธิภาพของโมเดลในระหว่างการทำ cross-validation

คำตอบ: เป็นค่าที่มีการเปลี่ยนแปลงด้วย Learning algorithm

คำอธิบาย: Hyper-parameters ถูกกำหนดโดยผู้ใช้งานก่อนเริ่มเทรน ส่วนค่าที่ปรับเปลี่ยนระหว่างเทรนคือ Model Parameters

ข้อที่ 3

โจทย์: หากต้องการวัด Unbiased generalisation performance ต้องแยก Test set ออกจากส่วนใด

ตัวเลือก:

- ถูกทุกข้อ
- Training
- Model selection
- Hyper-parameter tuning

คำตอบ: ถูกทุกข้อ (Training, Model selection, Hyper-parameter tuning)

คำอธิบาย: ต้องเก็บ Test set แยกไว้ต่างหากเพื่อป้องกัน Data Leakage และใช้ประเมินผลเพียงครั้งเดียวในตอนท้าย

ข้อที่ 4

โจทย์: ข้อใดคือคำจำกัดความของ Overfitting

ตัวเลือก:

- Training error < Test error
- เมื่อเพิ่ม Model complexity แล้ว Training error ลดลง แต่ Test error เพิ่มขึ้น
- Test error < Training error
- Training error สูง

คำตอบ: เมื่อเพิ่ม Model complexity แล้ว Training error ลดลง แต่ Test error เพิ่มขึ้น

คำอธิบาย: สถานะที่โมเดลจดจำ Noise ใน Training data มากเกินไปจนไม่สามารถทำนายข้อมูลใหม่ได้ดี

ข้อที่ 5

โจทย์: การแก้ปัญหา Overfitting ทำได้โดยวิธีใด

ตัวเลือก:

- ใส่ Regularisation term ลงไปใน Loss function
- ลดจำนวน Degrees of polynomials ในกรณีของ Linear regression models
- ถูกทุกข้อ
- เพิ่ม Training samples

คำตอบ: ถูกทุกข้อ (Regularisation, ลด Degree of polynomial, เพิ่ม Training samples)

คำอธิบาย: วิธีการเหล่านี้มุ่งเน้นการลดความซับซ้อนของโมเดลหรือเพิ่มข้อมูลเพื่อให้โมเดลเรียนรู้ Pattern จริง

ข้อที่ 6

โจทย์: Error ประเภทใดไม่ขึ้นอยู่กับ Model complexity หรือโมเดลที่เลือกใช้

ตัวเลือก:

- ถูกทุกข้อ
- Bias
- Variance
- Irreducible error

คำตอบ: Irreducible error

คำอธิบาย: เป็น Noise ที่เกิดจากธรรมชาติของข้อมูล ไม่สามารถลดทอนได้ไม่ว่าจะใช้โมเดลเก่งเพียงใด

ข้อที่ 7

โจทย์: ค่าของ Normalized root mean squared error (NRMSE) อยู่ในช่วงใด
ตัวเลือก:

- $[-1,1]$
- $[0,1]$
- $[0,\infty)$
- $(-\infty,\infty)$

คำตอบ: $[0, \infty)$

คำอธิบาย: RMSE เป็นบวกเสมอ และการ Normalization ด้วยค่าบวกทำให้ผลลัพธ์เริ่มที่ 0 และไม่มีขีดจำกัดบน

ข้อที่ 8

โจทย์: การจัดความพอใจเป็น positive หรือ negative เป็น Classification ประเภทใด
ตัวเลือก:

- Binary classification
- Multi-class classification
- Multi-label classification

คำตอบ: Binary classification

คำอธิบาย: เป็นการจัดกลุ่มข้อมูลออกเป็น 2 คลาสที่เป็นคู่ตรงข้ามกัน

ข้อที่ 9

โจทย์: ข้อใดคือชื่อของ Binary classifier
ตัวเลือก:

- Logistic regression
- Linear regression
- Ridge regression
- Lasso regression

คำตอบ: Logistic regression

คำอธิบาย: แม้ชื่อจะลงท้ายด้วย Regression แต่ทำงานโดยใช้ Sigmoid ฟังก์ชันเพื่อจัดกลุ่มข้อมูลเป็น 2 ประเภท

ข้อที่ 10

โจทย์: ข้อใดคือ Loss function ที่เหมาะสมในการทำ Binary classification
ตัวเลือก:

- Mean Absolute Error (MAE)
- Root Mean Squared Error (RMSE)

- Cross entropy loss
- ถูกทุกข้อ

คำตอบ: Cross entropy loss

คำอธิบาย: ถูกออกแบบมาเพื่อวัดความแตกต่างระหว่างความน่าจะเป็น (0-1) และใช้หลักการ Maximum Likelihood

ข้อที่ 11

โจทย์: ถ้าต้องการทำ Multi-class classification ที่สามารถได้ 4 คลาส จะต้องสร้าง Binary classifier อย่างน้อยที่สุดกี่อัน โดยที่คำนึงถึง Unknown class ด้วย

ตัวเลือก:

- 6
- 1
- 4
- 3

คำตอบ: 4

คำอธิบาย: ใช้เทคนิค One-vs-Rest (OvR) โดยสร้าง 1 ตัวต่อ 1 คลาส หากทั้ง 4 ตัวตอบ No ทั้งหมด จะสรุปได้ว่าเป็น Unknown

ข้อที่ 12

โจทย์: ตัวเลือกใดไม่ควรใช้เป็น Evaluation metrics สำหรับปัญหา Classification ได้

ตัวเลือก:

- Confusion matrix
- Accuracy
- Mean Squared
- Precision-recall และ F1-score

คำตอบ: Mean Squared Error (MSE)

คำอธิบาย: MSE ออกแบบมาสำหรับงาน Regression ที่ต้องการวัดระยะห่างเชิงตัวเลข ไม่เหมาะกับงานจัดหมวดหมู่ที่ระยะห่างระหว่างคลาสไม่มีความหมายเชิงเปรียบเทียบ

ข้อที่ 13

โจทย์: ข้อใดเรียงลำดับขั้นตอนในการ Machine learning project ไม่เหมาะสม

ตัวเลือก:

- Cross-validation -> Train model -> Evaluate model
- Split train-test -> Train model -> Evaluate model
- Over sampling -> Split train-test -> Train model -> Evaluate model
- Split train-test -> Data transformation ด้วย fit_transform บน training set -> Train model -> Evaluate model

คำตอบ: Over sampling -> Split train-test -> Train model -> Evaluate model

คำอธิบาย: การทำ Over sampling ต้องทำหลังจากการแบ่งข้อมูล (Split) แล้วเท่านั้น เพื่อป้องกัน Data Leakage

ข้อที่ 14

โจทย์: Output activation function ควรใช้สำหรับ Binary classification

ตัวเลือก:

- ReLu
- Sigmoid
- ไม่ใช่ Activation function
- Tanh

คำตอบ: Sigmoid

คำอธิบาย: Sigmoid บีบอัดค่าให้อยู่ในช่วง (0, 1) ซึ่งสอดคล้องกับคุณสมบัติของความน่าจะเป็นในงาน Binary classification

ข้อที่ 15

โจทย์: ตัวเลือกใดเป็นการทำ Regularization ใน SVM

ตัวเลือก:

- ใช้ Kernel ที่มีความซับซ้อนมากขึ้น
- ลดค่า λ สำหรับ Regression
- ลดค่า Slack variable
- เพิ่มค่า Slack variable

คำตอบ: เพิ่มค่า Slack variable (หรือลดค่า C)

คำอธิบาย: การยอมให้มี Slack variable มากขึ้น (ผ่านการลด C) ทำให้ Margin กว้างขึ้นและโมเดลยืดหยุ่นขึ้น ช่วยลด Overfitting

ข้อที่ 16

โจทย์: ข้อใดกล่าวถูกต้องเกี่ยวกับ Ensemble Learning

ตัวเลือก:

- ถูกทุกตัวเลือก
- Boosting ไม่สามารถสร้างโมเดลหลายๆโมเดลแบบ Parallel ได้ เนื่องจากต้องพยายามแก้ไข Error ที่เกิดจากโมเดลก่อนหน้า
- Stacking มีการเทรนโมเดลอีกตัวหนึ่งเพื่อมารวบรวมคำตอบเพื่อเป็นคำตอบสุดท้าย
- Bagging สามารถสร้างโมเดลหลายๆโมเดลแบบ Parallel ได้

คำตอบ: ถูกทุกตัวเลือก (Boosting เป็น Sequential, Stacking มี Meta-learner, Bagging เป็น Parallel)

คำอธิบาย: เป็นลักษณะเฉพาะของการทำงานในเทคนิค Ensemble แต่ละประเภท

ข้อที่ 17

โจทย์: ตัวเลือกใดไม่ใช่จุดประสงค์ของการทำ Feature engineering

ตัวเลือก:

- เพื่อทำให้ความสัมพันธ์ระหว่าง Features กับ Target มีความซับซ้อนลดลง
- เพื่อให้แปลความหมายได้เหมาะสมขึ้น
- เพื่อให้ข้อมูลมีความเหมาะสมในการเทรนโมเดลมากขึ้น
- เพื่อแก้ปัญหา Overfitting

คำตอบ: เพื่อทำให้ความสัมพันธ์ระหว่าง Features กับ Target มีความซับซ้อนลดลง

คำอธิบาย: ปกติ Feature Engineering มักใช้เพื่อเพิ่มความสัมพันธ์ที่ซ่อนอยู่ (อาจซับซ้อนขึ้นแต่ชัดเจนขึ้นสำหรับโมเดล) ไม่ใช่การลดความซับซ้อนของความสัมพันธ์โดยตรง

ข้อที่ 18

โจทย์: โมเดลในตัวเลือกใดไม่จำเป็นต้องทำ Feature scaling

ตัวเลือก:

- Linear regression
- Neural network
- Support vector machine
- Tree-based models

คำตอบ: Tree-based models

คำอธิบาย: การตัดสินใจของต้นไม้ใช้จุดตัด (Threshold) ที่ละฟิเจอร์ ไม่ได้วัดระยะห่างระหว่างฟิเจอร์ จึงไม่ได้รับผลกระทบจากสเกล

ข้อที่ 19

โจทย์: ข้อใดกล่าวถูกต้องเกี่ยวกับ SHAP

ตัวเลือก:

- SHAP ใช้ได้กับปัญหา Regression เท่านั้น
- SHAP เป็นวิธีที่ใช้ในการแปลความหมายของการทำนายว่า Features ใดมีความสำคัญเท่าไร
- SHAP ใช้ได้กับ Tree-based models เท่านั้น
- SHAP ใช้ได้กับปัญหา Classification เท่านั้น

คำตอบ: เป็นวิธีที่ใช้ในการแปลความหมายของการทำนายว่า Features ใดมีความสำคัญเท่าไร

คำอธิบาย: SHAP ใช้ทฤษฎีเกมเพื่อจัดสรรส่วนแบ่งความสำคัญให้แก่แต่ละ Feature ในการทำนายผลลัพธ์

5 Machine Learning Series: Unsupervised Learning

ข้อที่ 1

โจทย์: Supervised และ Unsupervised ต่างกันอย่างไร

ตัวเลือก:

- supervised learning มีตัวอย่าง target output แต่ unsupervised learning ไม่มี
- supervised learning มีผู้สอนกำหนด objective function ให้ แต่ unsupervised learning ไม่มี
- supervised learning เป็นการทำงานตามคำสั่ง แต่ unsupervised learning เป็นการทำงานแบบสุ่ม
- ทั้งสองรูปแบบไม่ต่างกัน

คำตอบ: Supervised มีเฉลย (Label), Unsupervised ไม่มีเฉลย

คำอธิบาย: Unsupervised เรียนรู้จากโครงสร้างข้อมูลดิบเพื่อค้นหา Pattern โดยปราศจากป้ายกำกับ

ข้อที่ 2

โจทย์: หลักการประเมิน Cluster ที่ดีคืออะไร

ตัวเลือก:

- สมาชิกใน cluster มีรูปแบบคล้ายๆ กัน
- สมาชิกต่าง cluster มีรูปแบบต่างกัน
- จำนวนสมาชิกใน cluster ไม่น้อยจนเกินไป
- ถูกทุกตัวเลือก

คำตอบ: ถูกทุกตัวเลือก (สมาชิกในกลุ่มเหมือนกัน, ต่างกลุ่มกันต่างกันมาก, จำนวนสมาชิกไม่น้อยเกินไป)

คำอธิบาย: Cluster ที่ดีควรมีความหนาแน่นภายในสูงและมีการแยกห่างระหว่างกลุ่มชัดเจนเพื่อให้เกิดนัยสำคัญ

ข้อที่ 3

โจทย์: distance กับ similarity ต่างกันอย่างไร

ตัวเลือก:

- distance ยาวได้ไม่จำกัด แต่ similarity มีค่าสูงสุดจำกัด
- distance มีค่าต่ำสุด แต่ similarity ไม่มีค่าต่ำสุด
- distance เป็นค่าต่อเนื่อง แต่ similarity เป็นค่าไม่ต่อเนื่อง
- distance ใช้กับตัวเลข ส่วน similarity ใช้กับข้อมูลชนิดกลุ่ม

คำตอบ: distance ยาวได้ไม่จำกัด แต่ similarity มีค่าสูงสุดจำกัด

คำอธิบาย: Distance วัดความห่าง (เริ่มที่ 0 ไปถึง ∞) ส่วน Similarity วัดความเหมือน (มักอยู่ในช่วง $[0, 1]$ หรือ $[-1, 1]$)

ข้อที่ 4

โจทย์: เราจะประเมินผล clustering ได้อย่างไรบ้าง

ตัวเลือก:

- ใช้ labeled data เข้ามาช่วย แล้วประเมินแบบเดียวกับ supervised learning
- วัดความคล้ายของสมาชิกภายใน cluster และความต่างของสมาชิกระหว่าง cluster
- วัดความแปรปรวนภายใน cluster
- ถูกทุกตัวเลือก

คำตอบ: ถูกทุกตัวเลือก (ใช้ labeled data, วัดความต่างระหว่างกลุ่ม, วัดความแปรปรวนภายใน)

คำอธิบาย: การประเมินทำได้ทั้งแบบ External (เทียบ Label) และ Internal (ดูโครงสร้างทางคณิตศาสตร์)

ข้อที่ 5

โจทย์: ตัวเลือกใดไม่ถูกต้องเกี่ยวกับระยะทางและความคล้าย

ตัวเลือก:

- Euclidean distance เหมาะกับข้อมูลที่เป็นตัวเลข มีค่าต่อเนื่อง
- Hamming distance เหมาะกับข้อมูลชนิดกลุ่ม
- Manhattan distance เหมาะกับข้อมูลที่เป็นตัวเลข
- Cosine similarity เหมาะกับข้อมูลที่แต่ละมิติมีการกระจายไม่เท่ากัน

คำตอบ: Cosine similarity เหมาะกับข้อมูลที่แต่ละมิติมีการกระจายไม่เท่ากัน (เป็นข้อที่กำกวมที่สุด)

คำอธิบาย: Cosine Similarity เน้นวัดทิศทางเวกเตอร์ ไม่ใช่คุณสมบัติหลักในการแก้ปัญหการกระจายข้อมูลที่ไม่เท่ากัน

ข้อที่ 6

โจทย์: ตัวเลือกใดเป็นสาเหตุให้ต้องลดมิติของข้อมูล

ตัวเลือก:

- เพื่อให้แสดงผลได้ง่าย
- เพื่อประหยัดพื้นที่ในการเก็บข้อมูล
- เพื่อเลือกเฉพาะข้อมูลที่เป็นประโยชน์
- ถูกทุกตัวเลือก

คำตอบ: ถูกทุกตัวเลือก (แสดงผลได้ง่าย, ประหยัดพื้นที่, เลือกเฉพาะข้อมูลที่เป็นประโยชน์)

คำอธิบาย: เพื่อให้ข้อมูลอยู่ในรูปแบบที่เรียบง่ายขึ้น (Simplified Representation) โดยยังรักษาใจความสำคัญ

ข้อที่ 7

โจทย์: จากรูปตัวเลือกใดเหมาะสมในการลดมิติข้อมูล Moons dataset ให้เหลือ 1 มิติ
ตัวเลือก:

- เลือกเฉพาะข้อมูลในแกน x1
- เลือกเฉพาะข้อมูลในแกน x2
- ใช้ PCA เลือกแกนหลักแกนแรก
- ใช้ t-SNE บีบข้อมูลให้เหลือแกนเดียว

ลักษณะรูปภาพ: ภาพแสดงชุดข้อมูล Moons dataset ซึ่งเป็นจุดข้อมูลที่เรียงตัวกันเป็นรูปพระจันทร์เสี้ยวสองวงที่ซ้อนเหลื่อมกันในระนาบ 2 มิติ

คำตอบ: t-SNE

คำอธิบาย: ข้อมูล Moons เป็น Non-linear การใช้ PCA จะทำให้ข้อมูลทับซ้อนกัน แต่ t-SNE สามารถรักษาโครงสร้างความใกล้เคียงได้ดีกว่า

ข้อที่ 8

โจทย์: ผลลัพธ์ใดสอดคล้องกับพฤติกรรมของ K-means บนข้อมูล Moons dataset
ตัวเลือก:

- คำตอบที่ถูกคือ A
- คำตอบที่ถูกคือ B
- คำตอบที่ถูกคือ C
- คำตอบที่ถูกคือ D

ลักษณะรูปภาพ: ภาพแสดงผลการแบ่งกลุ่มข้อมูล Moons dataset ด้วยอัลกอริทึมที่แตกต่างกัน (A-D)

คำตอบ: รูปที่ D

คำอธิบาย: K-means พยายามแบ่งพื้นที่ด้วยเส้นตรง (Decision boundary) จึงได้ผลลัพธ์เป็นการตัดผ่านกลุ่มข้อมูลในแนวระนาบ

ข้อที่ 9

โจทย์: เมื่อต้องการสร้าง cluster ของธุรกรรมออนไลน์ที่ประกอบด้วยยอดเงินและประเภทร้านค้า ควรเลือกตัวแทนอย่างไร
ตัวเลือก:

- Mean
- Mode
- Mean ของประเภทร้านค้า, Mode ของยอดเงิน ช่วงเวลา และ timezone
- Mean ของยอดเงิน, ช่วงเวลา และ mode ของ ประเภทร้านค้า timezone

คำตอบ: Mean ของยอดเงิน, ช่วงเวลา และ mode ของ ประเภทร้านค้า, timezone

คำอธิบาย: ข้อมูลเชิงปริมาณใช้ค่าเฉลี่ย (Mean) ส่วนข้อมูลเชิงกลุ่มใช้ฐานนิยม (Mode) เป็นตัวแทนที่เหมาะสม

ข้อที่ 10

โจทย์: ควรเลือกจำนวน cluster (k) อย่างไร

ตัวเลือก:

- ทดลองทีละค่า k จากน้อยไปมาก
- ตั้งให้จำนวน cluster มากกว่าที่คาดว่าจะได้ระดับหนึ่ง
- ใช้ elbow method
- ถูกทุกตัวเลือก

คำตอบ: ถูกทุกตัวเลือก (ทดลองทีละค่า, ตั้งมากกว่าที่คาดไว้เล็กน้อย, ใช้ elbow method)

คำอธิบาย: เป็นกระบวนการที่ใช้ร่วมกันเพื่อหาความสัมพันธ์ระหว่างความแม่นยำและความหมายทางธุรกิจ

ข้อที่ 11

โจทย์: ตัวเลือกใดเป็นวิธีการแบ่งกลุ่มข้อมูล (cluster) แบบมีลำดับ

ตัวเลือก:

- แบ่งกลุ่มใหญ่ก่อน แล้วค่อยๆ แบ่งกลุ่มย่อยในกลุ่มใหญ่
- สร้างกลุ่มย่อยก่อน แล้วค่อยๆ รวมกลุ่มย่อยเป็นกลุ่มใหญ่
- กำหนดจำนวนกลุ่มทั้งหมดที่ต้องการ แล้วใช้ K-Means clustering
- แบ่งกลุ่มใหญ่ก่อน แล้วค่อยๆ แบ่งกลุ่มย่อยในกลุ่มใหญ่ และ สร้างกลุ่มย่อยก่อน แล้วค่อยๆ รวมกลุ่มย่อยเป็นกลุ่มใหญ่

คำตอบ: แบ่งกลุ่มใหญ่ก่อนค่อยแบ่งย่อย และ สร้างกลุ่มย่อยก่อนค่อยรวมเป็นกลุ่มใหญ่

คำอธิบาย: ครอบคลุมทั้งวิธี Divisive (Top-down) และ Agglomerative (Bottom-up)

ข้อที่ 12

โจทย์: ตัวเลือกใดเป็นการกำหนดค่าเพื่อให้ได้ cluster ที่เป็นประโยชน์

ตัวเลือก:

- กำหนดจำนวนสมาชิกขั้นต่ำใน cluster
- กำหนดความแปรปรวนขั้นสูงใน cluster
- กำหนดความลึกสูงสุดของ cluster
- ถูกทุกตัวเลือก

คำตอบ: กำหนดจำนวนสมาชิกขั้นต่ำใน cluster

คำอธิบาย: เพื่อป้องกันการสร้างกลุ่มที่เป็น Noise หรือกลุ่มที่มีสมาชิกละเอียดเกินไปจนไม่มีความสำคัญทางสถิติ

ข้อที่ 13

โจทย์: จุดเด่นของ density-based clustering คืออะไร

ตัวเลือก:

- หาจุดกึ่งกลางของ cluster ได้ง่าย
- รองรับรูปร่างของ cluster หลากหลายรูปแบบ
- แบ่งข้อมูลเป็นลำดับชั้นได้สะดวก
- กำหนดจำนวน cluster ได้

คำตอบ: รองรับรูปร่างของ cluster หลากหลายรูปแบบ

คำอธิบาย: เนื่องจากทำงานตามความหนาแน่น ไม่ยึดติดกับจุดศูนย์กลาง จึงตรวจจับกลุ่มที่มีรูปร่างอิสระได้

ข้อที่ 14

โจทย์: DBSCAN สร้าง cluster ได้อย่างไร

ตัวเลือก:

- ลดระยะระหว่าง sample กับจุดศูนย์กลาง cluster
- พิจารณาจำนวน sample ใน cluster ณ ขณะหนึ่ง
- ลดความแปรปรวนของ sample ใน cluster ณ ขณะหนึ่ง
- รวม sample ในพื้นที่เล็ก ๆ ที่หนาแน่นพอไว้ด้วยกัน

คำตอบ: รวม sample ในพื้นที่เล็ก ๆ ที่หนาแน่นพอไว้ด้วยกัน

คำอธิบาย: ใช้พารามิเตอร์ Eps และ MinPts ในการเชื่อมต่อจุดที่อยู่ในพื้นที่หนาแน่นสูงเข้าด้วยกัน

ข้อที่ 15

โจทย์: ใน association rule เกณฑ์ใดกำหนดความน่าสนใจของ Frequent Itemset

ตัวเลือก:

- จำนวนครั้งที่ itemset นั้นปรากฏในชุดข้อมูล
- จำนวนชนิดของ item ใน itemset
- มูลค่ารวมของ itemset
- จำนวนชิ้นของ item ใน itemset

คำตอบ: Support (ความถี่ในการปรากฏ)

คำอธิบาย: Support บอกว่ารูปแบบพฤติกรรมนั้นเกิดขึ้นบ่อยเพียงใดในภาพรวมของชุดข้อมูลทั้งหมด

ข้อที่ 16

โจทย์: support กับ confidence ต่างกันอย่างไร

ตัวเลือก:

- ไม่แตกต่างกัน
- support ใช้ในการเลือก itemset ส่วน confidence ใช้ในการเรียงลำดับ itemset
- support ใช้กับ itemset 1 ชุด ส่วน confidence ใช้บอกความสัมพันธ์ของ itemset 2 ชุด
- support เป็นความน่าจะเป็น มีค่า 0-1 ส่วน confidence เป็นคะแนนมีค่าบวกลบได้

คำตอบ: support ใช้กับ itemset 1 ชุด ส่วน confidence ใช้บอกความสัมพันธ์ของ itemset 2 ชุด

คำอธิบาย: Support บอกความนิยมของสินค้าก่อนนั้น ส่วน Confidence บอกโอกาสที่สินค้า B จะถูกซื้อถ้าซื้อ A ไปแล้ว

ข้อที่ 17

โจทย์: เมื่อทำ matrix factorization $A = BC$ ตัวเลือกใดถูกต้อง

ตัวเลือก:

- เมื่อ $|T| < |V|$ จะทำให้ matrix B ที่ได้ สามารถใช้ประมาณค่าแทน matrix A ได้ โดยใช้พื้นที่ลดลง
- เราสามารถดูการกระจายของคำใน topic ได้โดยดูจากคำใน matrix C
- แต่ละแถว (row) ของ matrix A และ B เรียกว่า document vector
- ถูกทุกตัวเลือก

คำตอบ: ถูกทุกตัวเลือก

คำอธิบาย: ช่วยลดพื้นที่จัดเก็บ, ดูการกระจายคำใน topic ได้จาก matrix C และแต่ละแถวคือ document vector

ข้อที่ 18

โจทย์: เมื่อใช้ topic model จะหา topic vector ของเอกสารใหม่ที่ไม่ได้ใช้ train ได้อย่างไร

ตัวเลือก:

- กรณีที่เป็น matrix factorization ให้นำ word-topic distribution vector มาคูณกับ document-word vector
- กรณีที่เป็น LDA ให้ fit document ใหม่กับ model เดิม เพื่อหา topic distribution vector
- กรณีที่เป็น matrix factorization ให้เลือก vector ของเอกสารเดิมที่คล้ายกับเอกสารใหม่ที่สุดมาใช้
- ถูกทั้ง A และ B

คำตอบ: กรณีที่เป็น LDA ให้ fit document ใหม่กับ model เดิม เพื่อหา topic distribution vector

คำอธิบาย: เป็นกระบวนการ Inference มาตรฐานของ LDA เพื่อหาพารามิเตอร์แฝงสำหรับข้อมูลใหม่

ข้อที่ 19

โจทย์: ตัวเลือกใดเป็นตัวอย่างการใช้งาน semi-supervised learning

ตัวเลือก:

- เพิ่มจำนวนข้อมูลที่ใช้ในการ train model ขึ้นโดยไม่ต้องมี labeled data
- เพิ่มความแม่นยำของ classification model โดยอาศัย unlabeled data
- ปรับ model ให้เหมาะกับ data distribution ใหม่มากขึ้น
- ถูกทุกตัวเลือก

คำตอบ: เพิ่มความแม่นยำของ classification model โดยอาศัย unlabeled data

คำอธิบาย: ใช้ประโยชน์จากข้อมูลไม่มีฉลากปริมาณมากร่วมกับข้อมูลมีฉลากน้อยขึ้นเพื่อหาขอบเขตคลาสที่ดีขึ้น

ข้อที่ 20

โจทย์: หากจัดกลุ่มแล้วพบว่าได้ 4 กลุ่มที่มีสมาชิกพอๆ กัน ข้อใดถูกต้อง

ตัวเลือก:

- ขนาดของ cluster เหมาะสม
- ข้อมูลน่าจะมีการกระจายตัวที่ดี
- จำนวน cluster ที่ได้เหมาะสม
- ไม่สามารถสรุปได้

คำตอบ: ไม่สามารถสรุปได้

คำอธิบาย: อาจเป็นผลลัพธ์จากอัลกอริทึมที่บีบให้เท่ากัน หรือเป็นเรื่องบังเอิญ ไม่ได้การันตีความเหมาะสม

ข้อที่ 21

โจทย์: หากต้องเลือกระหว่างวิธี A B และ C ในการจัดกลุ่ม ควรใช้เกณฑ์ใด

ตัวเลือก:

- เปรียบเทียบ variance ใน cluster เมื่อใช้วิธี A, B, C เลือกวิธีที่ให้ variance ต่ำสุด
- เปรียบเทียบ similarity ภายใน cluster เมื่อใช้ A, B และ C เลือกวิธีที่ให้ similarity สูงสุด
- สร้าง labeled dataset แล้วเลือกวิธีที่ให้ผลเหมือน labeled dataset มากที่สุด
- ถูกทุกตัวเลือก

คำตอบ: ถูกทุกตัวเลือก (เทียบ variance, เทียบ similarity, เทียบ labeled dataset)

คำอธิบาย: เป็นเกณฑ์มาตรฐานในการประเมินประสิทธิภาพทั้งแบบเชิงโครงสร้างและแบบอ้างอิงความจริง

6 Machine Learning Series: Time Series Modeling

ข้อที่ 1

โจทย์: ข้อใดไม่ใช่ข้อมูลอนุกรมเวลา (Time Series)

ตัวเลือก:

- ค่าไฟฟ้าของห้องทุกห้องในคอนโดตอนเดือนมกราคม 2020
- ราคาหุ้นรายวันของบริษัทในกลุ่ม S&P500 ในช่วงสัปดาห์สุดท้ายของปี 2020
- ข้อมูลปริมาณน้ำฝนรายวันในปี 2020
- อุณหภูมิเฉลี่ยรายปีของประเทศไทยตั้งแต่ปี 1950 ถึง 2000

คำตอบ: ค่าไฟฟ้าของห้องทุกห้องในคอนโดตอนเดือนมกราคม 2020

คำอธิบาย: เป็นข้อมูลตัดขวาง (Cross-sectional) ณ จุดเวลาเดียว ไม่ได้ดูการเปลี่ยนแปลงตามลำดับเวลาของหน่วยเดิม

ข้อที่ 2

โจทย์: ข้อใดไม่ถูกต้องเกี่ยวกับข้อมูล time series

ตัวเลือก:

- ข้อมูล time series อาจมีข้อมูลที่ขาดหายไปได้ จะต้องมีการเติมข้อมูลที่ขาดหายไปก่อนประมวลผล
- ข้อมูล time series ต้องเก็บบนช่วงเวลาที่ยาวเท่า ๆ กัน
- ข้อมูล time series เป็นข้อมูลที่มีลักษณะเปลี่ยนแปลงไปตามเวลา
- ทุกข้อถูกต้องเกี่ยวกับ time series

คำตอบ: ข้อมูล time series ต้องเก็บบนช่วงเวลาที่ยาวเท่า ๆ กัน

คำอธิบาย: ไม่จำเป็นเสมอไป ข้อมูลบางประเภทเช่นราคาหุ้นรายธุรกรรมอาจบันทึกในช่วงเวลาที่ไม่สม่ำเสมอได้

ข้อที่ 3

โจทย์: ข้อมูลจำนวนผู้ป่วยใหม่รายวันในประเทศต่างๆ ดังรูป เป็นข้อมูลประเภทใด

ตัวเลือก:

- เป็น time series แบบ univariate
- ไม่ใช่ time series
- เป็น time series แบบ multivariate

ลักษณะรูปภาพ: ภาพแสดงกราฟเส้นจำนวนผู้ป่วย COVID-19 หลายเส้นตามแต่ละประเทศในช่วงเวลาเดียวกัน

คำตอบ: เป็น time series แบบ multivariate

คำอธิบาย: เนื่องจากมีการพิจารณาหลายตัวแปร (หลายประเทศ) ที่เปลี่ยนแปลงไปตามลำดับเวลาเดียวกัน

ข้อที่ 4

โจทย์: ลักษณะใดที่บ่งบอกว่าข้อมูลเป็น Additive time series

ตัวเลือก:

- Multiplicative
- Pseudo-additive
- Additive

ลักษณะรูปภาพ: ภาพแสดงกราฟความต้องการใช้ไฟฟ้า (Electricity Demand) ที่มีความผันผวนคงที่ตลอดช่วงเวลา

คำตอบ: Additive

คำอธิบาย: ใน Additive model ขนาดของความผันผวน (Seasonal variation) จะคงที่ ไม่แปรผันตามระดับแนวโน้มหลัก

ข้อที่ 5

โจทย์: จากกราฟ A, B, C จงระบุส่วนประกอบจากการ Decompose

ตัวเลือก:

- A – trend, B – seasonal, C – residual
- ไม่มีข้อถูก
- A – seasonal, B – residual, C – trend
- A – residual, B – trend, C – seasonal

ลักษณะรูปภาพ: ภาพแสดงองค์ประกอบ 3 ส่วน ได้แก่ กราฟ A (คลื่นซ้ำๆ), กราฟ B (ลุ่ม), กราฟ C (เส้นโค้งทิศทาง)

คำตอบ: A – seasonal, B – residual, C – trend

คำอธิบาย: Seasonal แสดงรูปแบบซ้ำๆ, Trend แสดงทิศทางระยะยาว และ Residual แสดงค่าที่เหลือที่เป็นสัญญาณรบกวน

ข้อที่ 6

โจทย์: ข้อใดไม่ถูกต้องเกี่ยวกับ time series decomposition

ตัวเลือก:

- Seasonal ของ time series สามารถมีได้หลายระดับ
- Trend ของ time series บ่งบอกถึงความสัมพันธ์ระหว่างเวลาปัจจุบันกับเวลาก่อนหน้า
- ถ้าเลือกวิธี decompose ที่เหมาะสมกับ time series จะได้ residual ที่มีขนาดเล็ก
- ข้อมูล time series จะประกอบด้วยสามส่วนเสมอ

คำตอบ: ข้อมูล time series จะประกอบด้วยสามส่วนเสมอ (และ Trend บ่งบอกความสัมพันธ์ปัจจุบันกับอดีต)

คำอธิบาย: ในทางวิชาการอาจมีส่วนประกอบอื่นเช่น Cyclical และ Trend บอกแค่ทิศทาง ไม่ได้บอกความสัมพันธ์เชิงโครงสร้างย้อนหลัง

ข้อที่ 7

โจทย์: ข้อใดกล่าวถูกต้องที่สุดเกี่ยวกับ stationary property ของ time series
ตัวเลือก:

- time series ที่ stationary จะมีค่า variance ที่ต่ำกว่า non-stationary
- time series ที่ stationary จะไม่มี seasonal แต่สามารถมี trend ได้
- time series ที่ non-stationary จะสามารถนำมาวิเคราะห์ได้ง่ายกว่า stationary
- ถ้าแบ่งข้อมูล stationary time series เป็นสองส่วน ค่า variance ของข้อมูลครึ่งแรกจะมีค่าเท่ากับของครึ่งหลัง

คำตอบ: ถ้าแบ่งข้อมูล stationary เป็นสองส่วน ค่า variance ของครึ่งแรกจะมีค่าเท่ากับของครึ่งหลัง

คำอธิบาย: ตามนิยามของ Stationary ความแปรปรวน (Variance) ต้องคงที่ตลอดเวลา

ข้อที่ 8

โจทย์: หลักฐานใดใช้สนับสนุนว่าข้อมูลเป็น stationary time series
ตัวเลือก:

- เฉพาะ D ก็เพียงพอ เพราะ ADF test ใช้วัดว่าข้อมูลนี้ stationary หรือไม่
- ทุกข้อ เพราะแต่ละข้อทดสอบกันคนละด้าน
- A, C, D, F เพราะล้วนเป็นข้อมูลสนับสนุนการเป็น stationary
- เฉพาะ A ก็เพียงพอ เพราะเป็นคุณลักษณะสำคัญของ time series

คำตอบ: A, C, D, F (Running mean คงที่, ไม่มี seasonal, ADF p-value ต่ำ, Autocorrelation ลดลงเร็ว)

คำอธิบาย: เป็นคุณสมบัติพื้นฐานและผลการทดสอบทางสถิติที่ยืนยันความคงที่ของข้อมูล

ข้อที่ 10

โจทย์: ถ้าจะแปลงข้อมูลให้กลายเป็น stationary จะต้องทำกระบวนการใดบ้าง
ตัวเลือก:

- ไม่สามารถปรับข้อมูลนี้ให้เป็น stationary ได้
- A,B
- A
- A,B,C

คำตอบ: A, B, C (ทำ Differencing ลด trend/seasonal และทำ log transformation)

คำอธิบาย: เพื่อจัดการทั้งความแปรปรวนที่ไม่คงที่, อิทธิพลของฤดูกาล และแนวโน้มของข้อมูล

ข้อที่ 11

โจทย์: ข้อใดไม่ใช่ประโยชน์ของการ smoothing

ตัวเลือก:

- สามารถเอามาเปลี่ยนให้ข้อมูล nonstationary กลายเป็น stationary ได้
- สามารถนำมาขบขันลักษณะสำคัญของ time series ให้เด่นชัดขึ้น
- สามารถนำมาใช้ทำนายอนาคตได้
- สามารถนำมาลด noise ในข้อมูลได้

คำตอบ: สามารถนำมาใช้ทำนายอนาคตได้

คำอธิบาย: Smoothing เป็นการจัดการข้อมูลอดีตเพื่อให้เห็น Pattern ชัดขึ้น แต่ไม่มีคุณสมบัติในการพยากรณ์อนาคตในตัวเอง

ข้อที่ 12

โจทย์: หากข้อมูลมี Seasonality แต่ไม่มี Trend ควรใช้ smoothing ประเภทใดดีที่สุด

ตัวเลือก:

- Double exponential moving average
- Single exponential moving average
- Triple exponential moving average
- Moving average

คำตอบ: Triple Exponential Smoothing (Holt-Winters)

คำอธิบาย: แม้จะบอกว่าไม่มี Trend แต่ในตระกูลนี้ มีเพียง Triple Smoothing เท่านั้นที่รองรับองค์ประกอบฤดูกาล (Seasonality)

ข้อที่ 13

โจทย์: ข้อใดเป็นเหตุผลหลักที่จะใช้ moving average แทน exponential moving average

ตัวเลือก:

- เมื่อ time series มีเติบโตที่ช้ากว่า exponential
- เมื่อต้องการให้ข้อมูลที่ smooth แล้วมีค่าใกล้เคียงข้อมูลดั้งเดิมมากขึ้น
- ควรใช้ exponential moving average เสมอ
- เมื่อต้องการให้น้ำหนักของข้อมูลในการเฉลี่ยเท่า ๆ กัน

คำตอบ: เมื่อต้องการให้น้ำหนักของข้อมูลในการเฉลี่ยเท่า ๆ กัน

คำอธิบาย: Simple Moving Average ให้น้ำหนักทุกจุดเท่ากัน ต่างจาก EMA ที่ให้น้ำหนักข้อมูลใหม่มากกว่า

ข้อที่ 14

โจทย์: SARIMA, ARIMA, ARMA จะทำงานได้ดีบนข้อมูลลักษณะใด

ตัวเลือก:

- ข้อมูล Stationary
- ข้อมูล Stationary และ ลักษณะของข้อมูลในอดีตบ่งบอกถึงลักษณะข้อมูลในอนาคต
- ข้อมูลที่มี seasonality ชัดเจน
- ลักษณะของข้อมูลในอดีตบ่งบอกถึงลักษณะข้อมูลในอนาคต

คำตอบ: ข้อมูล Stationary และ ลักษณะของข้อมูลในอดีตบ่งบอกถึงลักษณะข้อมูลในอนาคต

คำอธิบาย: ต้องมีความคงที่ทางสถิติและมีความสัมพันธ์กันเอง (Autocorrelation) เพื่อให้โมเดลเรียนรู้ได้

ข้อที่ 15

โจทย์: ข้อใดไม่ถูกต้องเกี่ยวกับทำนายบนข้อมูล time series

ตัวเลือก:

- มีกระบวนการเลือกโมเดล และประเมินผลของโมเดลที่คล้ายกับ supervised learning
- จะต้องแบ่งข้อมูล training และ testing ตามช่วงเวลา
- โมเดล SARIMA จะได้ผลดีที่สุด เพราะสามารถรับมือข้อมูลได้ทุกประเภท
- ถ้าข้อมูลที่ต้องการโมเดลมีการเปลี่ยนแปลงพิเศษในบางช่วงเวลาจะต้องมีการจัดการพิเศษกับข้อมูลตั้งต้น

คำตอบ: โมเดล SARIMA จะได้ผลดีที่สุด เพราะสามารถรับมือข้อมูลได้ทุกประเภท

คำอธิบาย: ไม่มีโมเดลเดียวที่เก่งที่สุด SARIMA เป็นเชิงเส้น หากข้อมูลซับซ้อนมาก Machine Learning อาจทำได้ดีกว่า

ข้อที่ 16

โจทย์: ข้อใดไม่ถูกต้องเกี่ยวกับโมเดล ARMA, ARIMA และ SARIMA

ตัวเลือก:

- Moving Average model คล้ายกับ linear regression ใน supervised learning ต่างตรงที่ Moving average จะใช้ความผิดพลาดของการทำนายก่อนหน้านี้เป็น feature
- Autoregressive model ใช้ประโยชน์จากสัมพันธ์ระหว่างช่วงเวลาของ time series ที่ปรากฏใน autocorrelation
- ส่วนของ I ในโมเดล ARIMA จะทำให้สามารถรับมือข้อมูลที่มี trend ได้
- เวลาใช้โมเดลให้เลือกค่า p q ที่ทำให้ได้ค่า error น้อยที่สุดใน training data

คำตอบ: เวลาใช้โมเดลให้เลือกค่า p q ที่ทำให้ได้ค่า error น้อยที่สุดใน training data

คำอธิบาย: การเลือกตาม training error อย่างเดียวจะนำไปสู่ Overfitting ควรใช้เกณฑ์เช่น AIC/BIC

ข้อที่ 17

โจทย์: ข้อใดถูกต้องที่สุดเกี่ยวกับ confidence interval

ตัวเลือก:

- Confidence interval ที่เปอร์เซ็นต์เดียวกันจะมีความกว้างเท่ากันเสมอ
- ถ้า 90% confidence interval คือช่วง 9-11 ค่าที่แท้จริงของข้อมูลจะอยู่ในช่วง 8-12
- Confidence interval จะกว้างขึ้นตาม % ค่า confidence
- ถ้า 90% confidence interval คือช่วง 9-11 มีโอกาส 90% ที่ค่าที่แท้จริงจะอยู่ในช่วง 9-11

คำตอบ: Confidence interval จะกว้างขึ้นตาม คำอธิบาย: เพื่อความมั่นใจที่สูงขึ้น ต้องขยายช่วงให้กว้างขึ้นเพื่อดักจับค่าที่แท้จริงได้ครอบคลุมมากขึ้น

ข้อที่ 18

โจทย์: ข้อใดไม่ถูกต้องเกี่ยวกับ Facebook Prophet

ตัวเลือก:

- สามารถใช้ค้นหา outlier ได้
- สามารถใช้งานได้แม้ว่าข้อมูลที่ใช้สร้างโมเดลกับข้อมูลจริงจะมีความแตกต่างกัน
- สามารถแบ่ง seasonal ได้หลายระดับ
- สามารถทำทุกอย่างที่ SARIMA ทำได้

คำตอบ: สามารถทำทุกอย่างที่ SARIMA ทำได้

คำอธิบาย: สองโมเดลมีปรัชญาต่างกัน Prophet เป็น Additive Curve Fitting ส่วน SARIMA เป็น Stochastic Process

ข้อที่ 19

โจทย์: กรณีใดที่ควรใช้ supervised learning แทน time series modeling

ตัวเลือก:

- ควรใช้ time series modeling กับข้อมูลที่มีความสัมพันธ์ระหว่างเวลาเสมอ
- มีข้อมูลน้อย เช่น มีรอบ seasonal เพียงหนึ่งรอบ
- โมเดลปริมาณน้ำฝน PM2.5 และอุณหภูมิในแต่ละวันของกรุงเทพ
- ต้องการศึกษา seasonal effect ในข้อมูล

คำตอบ: มีข้อมูลน้อย เช่น มีรอบ seasonal เพียงหนึ่งรอบ

คำอธิบาย: โมเดล Time Series ต้องการข้อมูลหลายรอบเพื่อแยก Trend/Seasonal หากน้อยไปควรใช้ Feature Engineering ใน Supervised แทน

ข้อที่ 20

โจทย์: ข้อใดไม่ถูกต้องเกี่ยวกับการโมเดล time series

ตัวเลือก:

- ควรใช้โมเดลที่ซับซ้อนที่สุดเพื่อจะได้รับมือกับข้อมูลทุกรูปแบบ
- การทำsmoothingก่อนเทรนโมเดลสามารถช่วยให้โมเดลรับมือกับ outlier ได้ดีขึ้น
- ถ้า time series เป็น multiplicative time series สามารถทำ log transform เพื่อใช้กับ additive model ได้
- ควรมีการ transform ข้อมูลเพื่อให้โมเดล stationary มากขึ้นก่อนนำมาเทรนกับโมเดล

คำตอบ: ควรใช้โมเดลที่ซับซ้อนที่สุดเพื่อจะได้รับมือกับข้อมูลทุกรูปแบบ

คำอธิบาย: ขัดกับหลัก Occam's Razor โมเดลซับซ้อนเกินไปมัก Overfit และอธิบายได้ยาก

ข้อที่ 21

โจทย์: ข้อใดไม่ถูกต้องเกี่ยวกับการประยุกต์ใช้ time series modeling

ตัวเลือก:

- สามารถนำมาทำโมเดลเพื่อแจ้งเตือนในช่วงเวลาที่ผิดปกติ
- สามารถนำ Confidence interval ของการทำนายใช้บอกจุดสูงสุดและต่ำสุดของความเป็นไปได้ของข้อมูลได้
- สามารถนำ time series มา decompose เพื่อแสดง trend ของข้อมูลในการประกอบการตัดสินใจได้
- เป็นการประยุกต์ใช้ที่ถูกต้องทุกข้อ

คำตอบ: สามารถนำ Confidence interval ของการทำนายใช้บอกจุดสูงสุดและต่ำสุดของความเป็นไปได้ของข้อมูลได้

คำอธิบาย: ต้องใช้ Prediction Interval (PI) ไม่ใช่ Confidence Interval (CI) เนื่องจาก PI ครอบคลุมความผันผวนของข้อมูลจริงด้วย