

รายงานสรุปข้อสอบและเฉลยรายวิชาด้าน Data Science และ Machine Learning

Gemini CLI Autonomous Agent

26 เมษายน พ.ศ. 2569

1 Learn Python: Language Basics and Fundamental Data Processing

ข้อที่ 1

โจทย์: Dynamically-typed language หมายความว่าอะไร

คำตอบ: ประเภทของตัวแปรถูกตัดสินตอน Run-Time จึงไม่ต้องกำหนดประเภทของตัวแปรก่อนใช้งาน

คำอธิบาย: ภาษาโปรแกรมที่มีลักษณะเป็น Dynamically-typed คือภาษาที่ "ประเภทของข้อมูล" ของตัวแปรจะถูกผูกติดอยู่กับค่า (Value) ที่เก็บอยู่ในตัวแปรในขณะนั้น การตัดสินประเภทข้อมูลจะเกิดขึ้นในขณะที่โปรแกรมกำลังทำงาน (Run-time)

ข้อที่ 2

โจทย์: อะไรเป็นหัวใจหลักที่ทำให้ Jupyter notebook เข้าใจภาษาโปรแกรมภาษาต่าง ๆ

คำตอบ: Kernel

คำอธิบาย: สถาปัตยกรรมของ Jupyter แยกส่วนแสดงผล (Notebook) ออกจากส่วนประมวลผล (Kernel) การรองรับหลายภาษาทำได้โดยการติดตั้ง Kernel เฉพาะของภาษานั้นๆ

ข้อที่ 3

โจทย์: ถ้าสมมติ ณ ตอนนี้มี 5 cell และ cell ปัจจุบันอยู่ที่ cell รองสุดท้าย หลังจากที่เรา cell ปัจจุบันด้วยการกดปุ่ม Shift+Enter สมมติว่าจะมีกี่ cell

คำตอบ: 5 cell

คำอธิบาย: เมื่อรัน Cell รองสุดท้าย (ลำดับที่ 4 จาก 5) ด้วย Shift+Enter ระบบจะเลื่อน Focus ไปยัง Cell ถัดไป (ลำดับที่ 5) โดยไม่มีการสร้าง Cell ใหม่ จำนวน Cell รวมจึงยังคงเป็น 5

ข้อที่ 4

โจทย์: หากต้องการแสดง block ของโค้ดใน Markdown cell เราสามารถทำได้อย่างไร

คำตอบ: ใส่ space จำนวนเท่ากันแต่ต้องอย่างน้อย 4 ตัวในส่วนต้นของบรรทัดของโค้ดที่อยู่ใน Block เดียวกัน

คำอธิบาย: การเว้นวรรค 4 ช่องหรือ 1 Tab เป็นมาตรฐานดั้งเดิม (Indented Code Block) ของ Markdown ในการสร้างส่วนแสดงผลโค้ด

ข้อที่ 5

โจทย์: ข้อใดเป็นผลลัพธ์ของโปรแกรมต่อไปนี้

```
1 x = 2
2 y = 4
3 y /= x
4 print(y)
```

คำตอบ: 2.0

คำอธิบาย: ตัวดำเนินการ / ใน Python 3 จะให้ผลลัพธ์เป็นทศนิยม (Float) เสมอ แม้การหารจะลงตัวก็ตาม

ข้อที่ 6

โจทย์: expression $4 + -1 * 4 / 2 ** 2$ มีค่าเท่ากับเท่าใด

คำตอบ: 3.0

คำอธิบาย: ลำดับความสำคัญเริ่มจากเลขยกกำลัง ($2 ** 2 = 4$) -> คูณ/หาร ($-1 * 4 / 4 = -1.0$) -> บวก ($4 + (-1.0) = 3.0$)

ข้อที่ 7

โจทย์: ให้ function funcA() มี definition ส่วนหัวเป็น funcA(*arg1 , arg2 = True) ในการเรียกใช้ funcA() จะต้องมีการใส่ argument จำนวนกี่ค่า

คำตอบ: 0 ค่า

คำอธิบาย: เนื่องจาก *arg1 เป็นการรับ Argument แบบไม่จำกัดจำนวน (รวมถึง 0 ค่า) และ arg2 มีค่าเริ่มต้น (Default value) จึงสามารถเรียกใช้ฟังก์ชันโดยไม่ส่ง Argument ใดๆ ได้เลย

ข้อที่ 8

โจทย์: ข้อใดเกิด implicit data type conversion และผลลัพธ์มี data type ไດ

คำตอบ: 3 + 4.0 ผลลัพธ์เป็น float

คำอธิบาย: เมื่อมีการดำเนินการระหว่าง Integer และ Float ระบบจะแปลง Integer เป็น Float โดยอัตโนมัติ (Type Promotion) เพื่อความแม่นยำ

ข้อที่ 9

โจทย์: ผลลัพธ์เมื่อรัน print(type("34" + 3)) คือข้อใด

คำตอบ: เกิด error

คำอธิบาย: Python เป็น Strong Typing ไม่ยอมให้เชื่อม (Concatenate) String เข้ากับ Integer โดยตรง จะเกิด TypeError

ข้อที่ 10

โจทย์: หลังจากรันโปรแกรมต่อไปนี้ ค่า x จะมีค่าเท่ากับปริมาณใด

```
1 x = 0
2 for i in range(1,1000,2):
3     if i%2 == 0:
4         x += i
```

คำตอบ: 0

คำอธิบาย: range(1, 1000, 2) ให้เลขคี่ทั้งหมด ซึ่งไม่มีทางที่ i%2 == 0 จะเป็นจริง เงื่อนไขการบวกจึงไม่เคยเกิดขึ้น ค่า x จึงยังคงเป็น 0

ข้อที่ 11

โจทย์: โปรแกรมต่อไปนี้ให้ผลลัพธ์อะไร

```
1 x = 1
2 y = 1000
3 while x <= y:
4     if abs(x-y) > 500:
5         y = 100
6         continue
7     elif abs(x-y) > 10:
8         y = 5
9         continue
10    else:
11        y -= 1
12    x += 1
```

13 `print(x)`

คำตอบ: 4

คำอธิบาย: โปรแกรมวนลูปโดยปรับค่า y จาก 1000 -> 100 -> 5 จากนั้นจึงเข้าสู่เงื่อนไข `else` เพื่อเพิ่มค่า x จนกระทั่ง `x > y` ผลสุดท้าย `x = 4`

ข้อที่ 12

โจทย์: ข้อใดถูกต้อง

คำตอบ: Python list มี items ที่เป็นข้อมูลประเภท list ปนกับข้อมูลประเภทอื่นได้

คำอธิบาย: Python list เป็น Heterogeneous collection ที่สามารถเก็บข้อมูลต่างชนิดกันรวมถึง List ซ้อนกันได้

ข้อที่ 13

โจทย์: ข้อใดถูกต้องสำหรับ Python Set

คำตอบ: เป็น unordered data collection

คำอธิบาย: Set ใน Python ไม่มีลำดับ (Unordered) และไม่สามารถเข้าถึงผ่าน Index ได้ รวมถึงเก็บค่าที่ไม่ซ้ำกันเท่านั้น

ข้อที่ 14

โจทย์: ข้อใดถูกต้อง ถ้ารันคำสั่ง `t1 = tuple('1234')`

คำตอบ: t1 จะมี 4 items ที่มีค่า '1', '2', '3' และ '4'

คำอธิบาย: ฟังก์ชัน `tuple()` จะแตกสมาชิกจาก Iterable (ในที่นี้คือ String) ออกมาทีละตัวละสร้างเป็น Tuple

ข้อที่ 15

โจทย์: ให้ product เป็น dictionary ที่มีค่า 'id': 'P123', 'name': 'watch', 'price': 5000 ถ้าต้องการเพิ่ม 'color' เป็นอีก key หนึ่ง ที่มีค่า 'silver' ต้องเขียน code อย่างไร

คำตอบ: `product['color'] = 'silver'`

คำอธิบาย: การเพิ่มหรืออัปเดต Key ใน Dictionary ทำได้โดยการกำหนดค่าผ่านวงเล็บก้ามปูโดยตรง

ข้อที่ 16

โจทย์: ข้อใดไม่ใช่ประโยชน์ของ Functions

คำตอบ: Availability

คำอธิบาย: Availability (ความพร้อมใช้งาน) เป็นคุณสมบัติของระบบงานในระดับโครงสร้างพื้นฐาน ไม่ใช่ประโยชน์โดยตรงจากการจัดโครงสร้างโค้ดด้วยฟังก์ชัน

ข้อที่ 17

โจทย์: จากฟังก์ชัน signature: `def create_customer(first_name, last_name, age, is_new_customer=True, **kwargs):`

ข้อใดทำให้เกิด error จากการเรียกใช้

คำตอบ: `create_customer('David', last_name='Berry', title='Mr.', occupation='programmer')`

คำอธิบาย: ขาด Argument ที่จำเป็น (Required Positional Argument) คือ `age`

ข้อที่ 18

โจทย์: ข้อใดคือประโยชน์ของการเปิดไฟล์ด้วย keyword `with`

คำตอบ: ไม่ต้องเรียกฟังก์ชัน `file close()` เพื่อปิดไฟล์ที่เปิดไว้ หลังจากออกจาก block ของ `with` แล้ว

คำอธิบาย: `with` ทำหน้าที่เป็น Context Manager ที่จะเรียกใช้เมธอดปิดไฟล์ให้อัตโนมัติเมื่อออกจากบล็อก

ข้อที่ 19

โจทย์: โปรแกรมต่อไปนี้ให้ผลลัพธ์อะไร

```
1 coor = [(1,2), (2,4), (3,6), (4,9)]  
2 print(list(map(lambda i: i[1]==2*i[0], coor)))
```

คำตอบ: [True, True, True, False]

คำอธิบาย: ตรวจสอบว่าสมาชิกตัวที่ 2 ใน Tuple เท่ากับ 2 เท่าของตัวแรกหรือไม่ (1,2)->T, (2,4)->T, (3,6)->T, (4,9)->F

ข้อที่ 20

โจทย์: ข้อใดคือลำดับชั้น scope ของ modules ใน Python จากใหญ่ไปเล็กที่สุด

คำตอบ: Package -> Python File -> Function

คำอธิบาย: Package บรรจุหลายไฟล์ (Modules), ไฟล์บรรจุคลาสและฟังก์ชันตามลำดับโครงสร้าง

2 รู้จักคอมพิวเตอร์และระบบดิจิทัล

ข้อที่ 1

โจทย์: ตัวเลือกใดแสดงแนวคิดของการทำงานโดยคอมพิวเตอร์เชิงไฟฟ้า

คำตอบ: หลักการเปิด/ปิดสวิตช์ แทนค่า 0 หรือ 1 ในเลขฐานสอง

คำอธิบาย: ทรานซิสเตอร์ทำหน้าที่เป็นสวิตช์ที่มีสถานะ เปิด (1) และ ปิด (0) ซึ่งเป็นพื้นฐานของระบบดิจิทัล

ข้อที่ 2

โจทย์: ทรานซิสเตอร์ถูกใช้อย่างไรในระบบคอมพิวเตอร์

คำตอบ: ใช้แทนสวิตช์เชิงไฟฟ้า

คำอธิบาย: ทรานซิสเตอร์ทำหน้าที่ควบคุมการไหลของกระแสไฟฟ้าเพื่อแทนค่าทางตรรกศาสตร์ (Boolean Logic)

ข้อที่ 3

โจทย์: กำหนดข้อมูลเลขฐานสอง ขนาด 8 หลักเป็น 10010000 ข้อใดถูกต้อง

คำตอบ: ถูกทุกตัวเลือก

คำอธิบาย: (1) บิตซ้ายสุดเป็น 1 คือค่าลบ (2) ไม่คิดเครื่องหมายได้ 144 (3) 8 บิตแทนได้ 256 รูปแบบ

ข้อที่ 4

โจทย์: หากกำหนด $A = 0$ และ $B = 1$ ตัวเลือกใดเป็นผลลัพธ์ของวงจรต่อไปนี้

ลักษณะรูปภาพ: ภาพแสดงวงจรลอจิกเกตที่ประกอบด้วย AND gate และ NOT gate ต่อร่วมกัน โดยรับอินพุต A และ B ผ่านเกตต่างๆ จนถึงเอาต์พุตสุดท้าย

คำตอบ: 1

คำอธิบาย: จากการไล่ลอจิก: $\text{NOT}(A \text{ AND } A) = 1$, $\text{NOT}(B \text{ AND } B) = 0$, $(1 \text{ AND } 0) = 0$, และ NOT ตัวสุดท้ายยกกลับค่า 0 เป็น 1

ข้อที่ 5

โจทย์: หากกำหนด $A = 0100$ และ $B = 0010$ ตัวเลือกใดเป็นผลลัพธ์ของ $A \text{ AND } B$

คำตอบ: 0000

คำอธิบาย: การทำ Bitwise AND ที่ละตำแหน่ง: $(0\&0)$, $(1\&0)$, $(0\&1)$, $(0\&0)$ ผลรวมเป็น 0000

ข้อที่ 6

โจทย์: จากตัวเลือกต่อไปนี้ หน่วยความจำแบบใดทำงานได้เร็วที่สุด

คำตอบ: CPU (Register)

คำอธิบาย: Register อยู่ภายใน CPU โดยตรง มีความเร็วสูงที่สุดเนื่องจากไม่มีความหน่วงจากการรับส่งผ่านบัสภายนอก

ข้อที่ 7

โจทย์: ตัวเลือกใดเป็นส่วนคำนวณของคอมพิวเตอร์

คำตอบ: CPU

คำอธิบาย: CPU (Central Processing Unit) มีหน่วย ALU ที่ทำหน้าที่คำนวณทางคณิตศาสตร์และตรรกศาสตร์

ข้อที่ 8

โจทย์: การทำงานร่วมกันของอุปกรณ์ฮาร์ดแวร์ต่างๆ เกิดขึ้นได้อย่างไร

คำตอบ: ระบบปฏิบัติการดำเนินการควบคุมและประสานงานการทำงานส่วนต่างๆ

คำอธิบาย: OS ทำหน้าที่เป็นศูนย์กลางบริหารจัดการทรัพยากร (CPU, RAM, Storage) ให้ทำงานสอดคล้องประสานกัน

ข้อที่ 9

โจทย์: ภาษาแอสเซมบลีคืออะไร

คำตอบ: ภาษาโปรแกรมซึ่งเทียบเท่ากับภาษาเครื่อง แต่เขียนให้อยู่ในรูปแบบที่อ่านได้ง่ายขึ้น

คำอธิบาย: เป็นภาษาระดับต่ำที่ใช้ตัวอักษรย่อ (Mnemonics) แทนรหัสเลขฐานสองของภาษาเครื่อง

ข้อที่ 10

โจทย์: การมี core หรือแกนประมวลผล มากขึ้น มีประโยชน์อย่างไร

คำตอบ: ถูกทุกตัวเลือก

คำอธิบาย: ช่วยในการทำ Multitasking, ขนานการประมวลผล (Parallelism) และรองรับผู้ใช้ได้มากขึ้น

ข้อที่ 11

โจทย์: ตัวเลือกใดเป็นหน้าที่ของระบบปฏิบัติการ

คำตอบ: ถูกทุกตัวเลือก

คำอธิบาย: ครอบคลุมการจัดสรรทรัพยากร, การควบคุมสิทธิการใช้งาน และการจัดการระบบเครือข่าย

ข้อที่ 12

โจทย์: เหตุใดไฟล์ภาพ JPG จากมือถือจึงเปิดบนคอมพิวเตอร์ได้แม้สถาปัตยกรรมต่างกัน

คำตอบ: เพราะโปรแกรมอ่านไฟล์เข้าใจข้อตกลงการแทนข้อมูลของไฟล์

คำอธิบาย: เกิดจากมาตรฐานรูปแบบไฟล์ (File Format Standards) ที่เป็นข้อตกลงร่วมกันในการเก็บข้อมูล

ข้อที่ 13

โจทย์: ตัวเลือกใดถูกต้องเกี่ยวกับการเก็บข้อมูลภาพ

คำตอบ: ถูกทุกตัวเลือก

คำอธิบาย: ครอบคลุมทั้งการเก็บองค์ประกอบสี (RGB), การแบ่งเป็นจุด (Bitmap/Pixel) และการใช้สมการ (Vector)

ข้อที่ 14

โจทย์: หากข้อมูลทุกรูปแบบเก็บเป็นเลขฐานสอง ข้อใดถูกต้อง

คำตอบ: ถูกทุกตัวเลือก

คำอธิบาย: ข้อมูลดิจิทัลคือชุดตัวเลข ความหมายขึ้นอยู่กับวิธีการตีความของโปรแกรมที่นำไปเปิด

ข้อที่ 15

โจทย์: หากกำหนด $A = 0$ และ $B = 1$ ตัวเลือกใดเป็นผลลัพธ์ของวงจรต่อไปนี้

ลักษณะรูปภาพ: ภาพแสดงสัญลักษณ์ของ XOR Gate (Exclusive OR Gate) ที่รับอินพุต A และ B

คำตอบ: 1

คำอธิบาย: XOR Gate จะให้ผลลัพธ์เป็น 1 เมื่ออินพุตต่างกัน (0 และ 1)

3 รู้จักปัญญาประดิษฐ์ และการเรียนรู้ของเครื่อง

ข้อที่ 1

โจทย์: ข้อใดเป็นคำที่ตีความได้แตกต่างกันมากที่สุดในคำนิยามของปัญญาประดิษฐ์

คำตอบ: ความฉลาด

คำอธิบาย: "ความฉลาด" เป็นนามธรรมที่ไม่มีนิยามสากลและมีการตีความหลากหลายในเชิงจิตวิทยาและวิทยาการคอมพิวเตอร์

ข้อที่ 2

โจทย์: การทดสอบทัวริง (Turing Test) เกี่ยวข้องกับข้อใดมากที่สุด

คำตอบ: การเลียนแบบมนุษย์ด้านการสื่อสาร

คำอธิบาย: เป็นการทดสอบความสามารถของเครื่องจักรในการสื่อสารผ่านตัวอักษรให้แนบเนียนจนมนุษย์แยกไม่ออก

ข้อที่ 3

โจทย์: ข้อใดเปรียบของระบบปัญญาประดิษฐ์ที่มีมากกว่ามนุษย์คือข้อใด

คำตอบ: คำนวณทางคณิตศาสตร์ได้ดีกว่ามนุษย์

คำอธิบาย: คอมพิวเตอร์ประมวลผลตัวเลขมหาศาลได้แม่นยำและรวดเร็วกว่ามนุษย์ที่จำกัดด้วยความเหนื่อยล้า

ข้อที่ 4

โจทย์: ข้อใดไม่ใช่ตัวอย่างของการประยุกต์ใช้งานทางปัญญาประดิษฐ์

คำตอบ: การค้นหาประวัติคนไข้จากบาร์โค้ด (Barcode)

คำอธิบาย: การสแกนบาร์โค้ดเป็นการเข้าถึงข้อมูลจากฐานข้อมูลโดยตรง ไม่มีการเรียนรู้หรือการตัดสินใจที่ซับซ้อนแบบ AI

ข้อที่ 5

โจทย์: การหาวิธีการเลื่อนแผ่นในเกม 8-Puzzle ไม่เกี่ยวข้องกับข้อใด

คำตอบ: การเข้าใจภาษาธรรมชาติ

คำอธิบาย: เกม 8-Puzzle แก้ไขด้วยตรรกศาสตร์และการค้นหาในพื้นที่สถานะ (State Space) ไม่เกี่ยวกับการประมวลผลภาษา

ข้อที่ 6

โจทย์: ข้อใดคือปัญหาของการใช้การค้นหาแบบ Depth First Search (DFS)

คำตอบ: หน่วยความจำที่ต้องใช้

คำอธิบาย: DFS ต้องเก็บเส้นทางใน Stack หากกราฟลึกมากอาจเกิดปัญหาหน่วยความจำเต็มหรือ Stack Overflow

ข้อที่ 7

โจทย์: ข้อใดเป็นข้อดีของการใช้ต้นไม้ตัดสินใจ (Decision Tree)

คำตอบ: มนุษย์สามารถเข้าใจผลลัพธ์จากโมเดลได้ง่ายกว่าการเรียนรู้ในแบบอื่น ๆ

คำอธิบาย: เป็นโมเดลแบบกล่องขาว (White-box) ที่แสดงขั้นตอนการตัดสินใจในรูปแบบ Flowchart ที่มนุษย์อ่านได้

ข้อที่ 8

โจทย์: ในการจำแนกรูปภาพ นิยมใช้การเรียนรู้แบบใด

คำตอบ: นิวรอลเน็ตเวิร์กแบบคอนโวลูชัน (Convolutional Neural Network - CNN)

คำอธิบาย: CNN ถูกออกแบบมาเพื่อตรวจจับคุณลักษณะเชิงพื้นที่ (Spatial Features) ในรูปภาพได้โดยอัตโนมัติ

ข้อที่ 9

โจทย์: ข้อใดคือหัวใจสำคัญของกระบวนการการเรียนรู้ของเครื่อง

คำตอบ: ลดข้อผิดพลาด (Error) บนตัวอย่างที่ใช้เรียนรู้

คำอธิบาย: การเรียนรู้คือการปรับพารามิเตอร์เพื่อทำให้ความแตกต่างระหว่างค่าทำนายและค่าจริง (Loss/Error) ต่ำที่สุด

ข้อที่ 10

โจทย์: อัลกอริทึมใดเหมาะกับการพยากรณ์แนวโน้มค่าต่อเนื่อง เช่น ราคาหุ้น

คำตอบ: การวิเคราะห์การถดถอยเชิงเส้น (Linear Regression)

คำอธิบาย: Regression ออกแบบมาเพื่อทำนายค่าตัวเลขต่อเนื่องและระบุทิศทางความสัมพันธ์ของข้อมูล

4 Machine Learning Series: Supervised Learning

ข้อที่ 1

โจทย์: ข้อใดกล่าวผิดเกี่ยวกับ Loss function

คำตอบ: ค่า Loss เยอะๆ ยิ่งดี

คำอธิบาย: Loss Function วัดความผิดพลาด เป้าหมายคือการทำให้น้ำหนักน้อยที่สุดเพื่อให้โมเดลแม่นยำที่สุด

ข้อที่ 2

โจทย์: ข้อใดกล่าวผิดเกี่ยวกับ Hyper-parameters

คำตอบ: เป็นค่าที่มีการเปลี่ยนแปลงด้วย Learning algorithm

คำอธิบาย: Hyper-parameters ถูกกำหนดโดยผู้ใช้งานก่อนเริ่มเทรน ส่วนค่าที่ปรับเปลี่ยนระหว่างเทรนคือ Model Parameters

ข้อที่ 3

โจทย์: หากต้องการวัด Unbiased generalisation performance ต้องแยก Test set ออกจากส่วนใด

คำตอบ: ถูกทุกข้อ (Training, Model selection, Hyper-parameter tuning)

คำอธิบาย: ต้องเก็บ Test set แยกไว้ต่างหากเพื่อป้องกัน Data Leakage และใช้ประเมินผลเพียงครั้งเดียวในตอนท้าย

ข้อที่ 4

โจทย์: ข้อใดคือคำจำกัดความของ Overfitting

คำตอบ: เมื่อเพิ่ม Model complexity แล้ว Training error ลดลง แต่ Test error เพิ่มขึ้น

คำอธิบาย: สภาวะที่โมเดลจดจำ Noise ใน Training data มากเกินไปจนไม่สามารถทำนายข้อมูลใหม่ได้ดี

ข้อที่ 5

โจทย์: การแก้ปัญหา Overfitting ทำได้โดยวิธีใด

คำตอบ: ถูกทุกข้อ (Regularisation, ลด Degree of polynomial, เพิ่ม Training samples)

คำอธิบาย: วิธีการเหล่านี้มุ่งเน้นการลดความซับซ้อนของโมเดลหรือเพิ่มข้อมูลเพื่อให้โมเดลเรียนรู้ Pattern จริง

ข้อที่ 6

โจทย์: Error ประเภทใดไม่ขึ้นอยู่กับ Model complexity หรือโมเดลที่เลือกใช้

คำตอบ: Irreducible error

คำอธิบาย: เป็น Noise ที่เกิดจากธรรมชาติของข้อมูล ไม่สามารถลดทอนได้ไม่ว่าจะใช้โมเดลเก่งเพียงใด

ข้อที่ 7

โจทย์: ค่าของ Normalized root mean squared error (NRMSE) อยู่ในช่วงใด

คำตอบ: $[0, \infty)$

คำอธิบาย: RMSE เป็นบวกเสมอ และการ Normalization ด้วยค่าบวกทำให้ผลลัพธ์เริ่มที่ 0 และไม่มีขีดจำกัดบน

ข้อที่ 8

โจทย์: การจัดความพอใจเป็น positive หรือ negative เป็น Classification ประเภทใด

คำตอบ: Binary classification

คำอธิบาย: เป็นการจัดกลุ่มข้อมูลออกเป็น 2 คลาสที่เป็นคู่ตรงข้ามกัน

ข้อที่ 9

โจทย์: ข้อใดคือชื่อของ Binary classifier

คำตอบ: Logistic regression

คำอธิบาย: แม้ชื่อจะลงท้ายด้วย Regression แต่ทำงานโดยใช้ Sigmoid ฟังก์ชันเพื่อจัดกลุ่มข้อมูลเป็น 2 ประเภท

ข้อที่ 10

โจทย์: ข้อใดคือ Loss function ที่เหมาะสมในการทำ Binary classification

คำตอบ: Cross entropy loss

คำอธิบาย: ถูกออกแบบมาเพื่อวัดความแตกต่างระหว่างความน่าจะเป็น (0-1) และใช้หลักการ Maximum Likelihood

ข้อที่ 11

โจทย์: ถ้าต้องการทำ Multi-class classification ที่สามารถได้ 4 คลาส จะต้องสร้าง Binary classifier อย่างน้อยที่สุดกี่อัน โดยที่คำนึงถึง Unknown class ด้วย

คำตอบ: 4

คำอธิบาย: ใช้เทคนิค One-vs-Rest (OvR) โดยสร้าง 1 ตัวต่อ 1 คลาส หากทั้ง 4 ตัวตอบ No ทั้งหมด จะสรุปได้ว่าเป็น Unknown

ข้อที่ 12

โจทย์: ตัวเลือกใดไม่ควรใช้เป็น Evaluation metrics สำหรับปัญหา Classification ได้

คำตอบ: Mean Squared Error (MSE)

คำอธิบาย: MSE ออกแบบมาสำหรับงาน Regression ที่ต้องการวัดระยะห่างเชิงตัวเลข ไม่เหมาะกับงานจัดหมวดหมู่ที่ระยะห่างระหว่างคลาสไม่มีความหมายเชิงเปรียบเทียบ

ข้อที่ 13

โจทย์: ข้อใดเรียงลำดับขั้นตอนในการ Machine learning project ไม่เหมาะสม

คำตอบ: Over sampling -> Split train-test -> Train model -> Evaluate model

คำอธิบาย: การทำ Over sampling ต้องทำหลังจากการแบ่งข้อมูล (Split) แล้วเท่านั้น เพื่อป้องกัน Data Leakage

ข้อที่ 14

โจทย์: Output activation function ควรใช้สำหรับ Binary classification

คำตอบ: Sigmoid

คำอธิบาย: Sigmoid บีบอัดค่าให้อยู่ในช่วง (0, 1) ซึ่งสอดคล้องกับคุณสมบัติของความน่าจะเป็นในงาน Binary classification

ข้อที่ 15

โจทย์: ตัวเลือกใดเป็นการทำ Regularization ใน SVM

คำตอบ: เพิ่มค่า Slack variable (หรือลดค่า C)

คำอธิบาย: การยอมให้มี Slack variable มากขึ้น (ผ่านการลด C) ทำให้ Margin กว้างขึ้นและโมเดลยืดหยุ่นขึ้น ช่วยลด Overfitting

ข้อที่ 16

โจทย์: ข้อใดกล่าวถูกต้องเกี่ยวกับ Ensemble Learning

คำตอบ: ถูกทุกตัวเลือก (Boosting เป็น Sequential, Stacking มี Meta-learner, Bagging เป็น Parallel)

คำอธิบาย: เป็นลักษณะเฉพาะของการทำงานในเทคนิค Ensemble แต่ละประเภท

ข้อที่ 17

โจทย์: ตัวเลือกใดไม่ใช่จุดประสงค์ของการทำ Feature engineering

คำตอบ: เพื่อให้ความสัมพันธ์ระหว่าง Features กับ Target มีความซับซ้อนลดลง

คำอธิบาย: ปกติ Feature Engineering มักใช้เพื่อเพิ่มความสัมพันธ์ที่ซ่อนอยู่ (อาจซับซ้อนขึ้นแต่ชัดเจนขึ้นสำหรับโมเดล) ไม่ใช่การลดความซับซ้อนของความสัมพันธ์โดยตรง

ข้อที่ 18

โจทย์: โมเดลในตัวเลือกใดไม่จำเป็นต้องทำ Feature scaling

คำตอบ: Tree-based models

คำอธิบาย: การตัดสินใจของต้นไม้ใช้จุดตัด (Threshold) ที่ละฟีเจอร์ ไม่ได้วัดระยะห่างระหว่างฟีเจอร์ จึงไม่ได้รับผลกระทบจากสเกล

ข้อที่ 19

โจทย์: ข้อใดกล่าวถูกต้องเกี่ยวกับ SHAP

คำตอบ: เป็นวิธีที่ใช้ในการแปลความหมายของการทำนายว่า Features ใดมีความสำคัญเท่าไร

คำอธิบาย: SHAP ใช้ทฤษฎีเกมเพื่อจัดสรรส่วนแบ่งความสำคัญให้แต่ละ Feature ในการทำนายผลลัพธ์

5 Machine Learning Series: Unsupervised Learning

ข้อที่ 1

โจทย์: Supervised และ Unsupervised ต่างกันอย่างไร

คำตอบ: Supervised มีเฉลย (Label), Unsupervised ไม่มีเฉลย

คำอธิบาย: Unsupervised เรียนรู้จากโครงสร้างข้อมูลดิบเพื่อค้นหา Pattern โดยปราศจากป้ายกำกับ

ข้อที่ 2

โจทย์: หลักการประเมิน Cluster ที่ดีคืออะไร

คำตอบ: ถูกทุกตัวเลือก (สมาชิกในกลุ่มเหมือนกัน, ต่างกลุ่มกันต่างกันมาก, จำนวนสมาชิกไม่น้อยเกินไป)

คำอธิบาย: Cluster ที่ดีควรมีความหนาแน่นภายในสูงและมีการแยกห่างระหว่างกลุ่มชัดเจนเพื่อให้เกิดนัยสำคัญ

ข้อที่ 3

โจทย์: distance กับ similarity ต่างกันอย่างไร

คำตอบ: distance ยาวได้ไม่จำกัด แต่ similarity มีค่าสูงสุดจำกัด

คำอธิบาย: Distance วัดความห่าง (เริ่มที่ 0 ไปถึง ∞) ส่วน Similarity วัดความเหมือน (มักอยู่ในช่วง $[0, 1]$ หรือ $[-1, 1]$)

ข้อที่ 4

โจทย์: เราจะประเมินผล clustering ได้อย่างไรบ้าง

คำตอบ: ถูกทุกตัวเลือก (ใช้ labeled data, วัดความต่างระหว่างกลุ่ม, วัดความแปรปรวนภายใน)

คำอธิบาย: การประเมินทำได้ทั้งแบบ External (เทียบ Label) และ Internal (ดูโครงสร้างทางคณิตศาสตร์)

ข้อที่ 5

โจทย์: ตัวเลือกใดไม่ถูกต้องเกี่ยวกับระยะทางและความคล้าย

คำตอบ: Cosine similarity เหมาะกับข้อมูลที่แต่ละมิติมีการกระจายไม่เท่ากัน (เป็นข้อที่กำกวมที่สุด)

คำอธิบาย: Cosine Similarity เน้นทิศทางทางเวกเตอร์ ไม่ใช่คุณสมบัติหลักในการแก้ปัญหาการกระจายข้อมูลที่ไม่เท่ากัน

ข้อที่ 6

โจทย์: ตัวเลือกใดเป็นสาเหตุให้ต้องลดมิติของข้อมูล

คำตอบ: ถูกทุกตัวเลือก (แสดงผลได้ง่าย, ประหยัดพื้นที่, เลือกเฉพาะข้อมูลที่เป็นประโยชน์)

คำอธิบาย: เพื่อให้ข้อมูลอยู่ในรูปแบบที่เรียบง่ายขึ้น (Simplified Representation) โดยยังรักษาใจความสำคัญ

ข้อที่ 7

โจทย์: จากรูปตัวเลือกใดเหมาะสมในการลดมิติข้อมูล Moons dataset ให้เหลือ 1 มิติ

ลักษณะรูปภาพ: ภาพแสดงชุดข้อมูล Moons dataset ซึ่งเป็นจุดข้อมูลที่เรียงตัวกันเป็นรูปพระจันทร์เสี้ยวสองวงที่ซ้อนเหลื่อมกันในระนาบ 2 มิติ

คำตอบ: t-SNE

คำอธิบาย: ข้อมูล Moons เป็น Non-linear การใช้ PCA จะทำให้ข้อมูลทับซ้อนกัน แต่ t-SNE สามารถรักษาโครงสร้างความใกล้เคียงได้ดีกว่า

ข้อที่ 8

โจทย์: ผลลัพธ์ใดสอดคล้องกับพฤติกรรมของ K-means บนข้อมูล Moons dataset

ลักษณะรูปภาพ: ภาพแสดงผลลัพธ์การแบ่งกลุ่มข้อมูล Moons dataset ด้วยอัลกอริทึมที่แตกต่างกัน (A-D)

คำตอบ: รูปที่ D

คำอธิบาย: K-means พยายามแบ่งพื้นที่ด้วยเส้นตรง (Decision boundary) จึงได้ผลลัพธ์เป็นการตัดผ่านกลุ่มข้อมูลในแนวนอน

ข้อที่ 9

โจทย์: เมื่อต้องการสร้าง cluster ของธุรกรรมออนไลน์ที่ประกอบด้วยยอดเงินและประเภทร้านค้า ควรเลือกตัวแทนอย่างไร

คำตอบ: Mean ของยอดเงิน, ช่วงเวลา และ mode ของ ประเภทร้านค้า, timezone

คำอธิบาย: ข้อมูลเชิงปริมาณใช้ค่าเฉลี่ย (Mean) ส่วนข้อมูลเชิงกลุ่มใช้ฐานนิยม (Mode) เป็นตัวแทนที่เหมาะสม

ข้อที่ 10

โจทย์: ควรเลือกจำนวน cluster (k) อย่างไร

คำตอบ: ถูกทุกตัวเลือก (ทดลองทีละค่า, ตั้งมากกว่าที่คาดไว้เล็กน้อย, ใช้ elbow method)

คำอธิบาย: เป็นกระบวนการที่ใช้ร่วมกันเพื่อหาความสัมพันธ์ระหว่างความแม่นยำและความหมายทางธุรกิจ

ข้อที่ 11

โจทย์: ตัวเลือกใดเป็นวิธีการแบ่งกลุ่มข้อมูล (cluster) แบบมีลำดับ

คำตอบ: แบ่งกลุ่มใหญ่ก่อนค่อยแบ่งย่อย และ สร้างกลุ่มย่อยก่อนค่อยรวมเป็นกลุ่มใหญ่

คำอธิบาย: ครอบคลุมทั้งวิธี Divisive (Top-down) และ Agglomerative (Bottom-up)

ข้อที่ 12

โจทย์: ตัวเลือกใดเป็นการกำหนดค่าเพื่อให้ได้ cluster ที่เป็นประโยชน์

คำตอบ: กำหนดจำนวนสมาชิกขั้นต่ำใน cluster

คำอธิบาย: เพื่อป้องกันการสร้างกลุ่มที่เป็น Noise หรือกลุ่มที่มีสมาชิกน้อยเกินไปจนไม่มีความสำคัญทางสถิติ

ข้อที่ 13

โจทย์: จุดเด่นของ density-based clustering คืออะไร

คำตอบ: รองรับรูปร่างของ cluster หลากหลายรูปแบบ

คำอธิบาย: เนื่องจากทำงานตามความหนาแน่น ไม่ยึดติดกับจุดศูนย์กลาง จึงตรวจจับกลุ่มที่มีรูปร่างอิสระได้

ข้อที่ 14

โจทย์: DBSCAN สร้าง cluster ได้อย่างไร

คำตอบ: รวม sample ในพื้นที่เล็ก ๆ ที่หนาแน่นพอไว้ด้วยกัน

คำอธิบาย: ใช้พารามิเตอร์ Eps และ MinPts ในการเชื่อมต่อจุดที่อยู่ในพื้นที่หนาแน่นสูงเข้าด้วยกัน

ข้อที่ 15

โจทย์: ใน association rule เกณฑ์ใดกำหนดความน่าสนใจของ Frequent Itemset

คำตอบ: Support (ความถี่ในการปรากฏ)

คำอธิบาย: Support บอกว่ารูปแบบพฤติกรรมนั้นเกิดขึ้นบ่อยเพียงใดในภาพรวมของชุดข้อมูลทั้งหมด

ข้อที่ 16

โจทย์: support กับ confidence ต่างกันอย่างไร

คำตอบ: support ใช้กับ itemset 1 ชุด ส่วน confidence ใช้บอกความสัมพันธ์ของ itemset 2 ชุด

คำอธิบาย: Support บอกความนิยมของสินค้าก่อนนั้น ส่วน Confidence บอกโอกาสที่สินค้า B จะถูกซื้อถ้าซื้อ A ไปแล้ว

ข้อที่ 17

โจทย์: เมื่อทำ matrix factorization $A = BC$ ตัวเลือกใดถูกต้อง

คำตอบ: ถูกทุกตัวเลือก

คำอธิบาย: ช่วยลดพื้นที่จัดเก็บ, การกระจายค่าใน topic ได้จาก matrix C และแต่ละแถวคือ document vector

ข้อที่ 18

โจทย์: เมื่อใช้ topic model จะหา topic vector ของเอกสารใหม่ที่ไม่ได้ใช้ train ได้อย่างไร

คำตอบ: กรณีที่เป็น LDA ให้ fit document ใหม่กับ model เดิม เพื่อหา topic distribution vector

คำอธิบาย: เป็นกระบวนการ Inference มาตรฐานของ LDA เพื่อหาพารามิเตอร์แฝงสำหรับข้อมูลใหม่

ข้อที่ 19

โจทย์: ตัวเลือกใดเป็นตัวอย่างการใช้งาน semi-supervised learning

คำตอบ: เพิ่มความแม่นยำของ classification model โดยอาศัย unlabeled data

คำอธิบาย: ใช้ประโยชน์จากข้อมูลไม่มีฉลากปริมาณมากร่วมกับข้อมูลมีฉลากน้อยขึ้นเพื่อหาขอบเขตคลาสที่ดีขึ้น

ข้อที่ 20

โจทย์: หากจัดกลุ่มแล้วพบว่าได้ 4 กลุ่มที่มีสมาชิกพอๆ กัน ข้อใดถูกต้อง

คำตอบ: ไม่สามารถสรุปได้

คำอธิบาย: อาจเป็นผลลัพธ์จากอัลกอริทึมที่บีบให้เท่ากัน หรือเป็นเรื่องบังเอิญ ไม่ได้การันตีความเหมาะสม

ข้อที่ 21

โจทย์: หากต้องเลือกระหว่างวิธี A B และ C ในการจัดกลุ่ม ควรใช้เกณฑ์ใด

คำตอบ: ถูกทุกตัวเลือก (เทียบ variance, เทียบ similarity, เทียบ labeled dataset)

คำอธิบาย: เป็นเกณฑ์มาตรฐานในการประเมินประสิทธิภาพทั้งแบบเชิงโครงสร้างและแบบอ้างอิงความจริง

6 Machine Learning Series: Time Series Modeling

ข้อที่ 1

โจทย์: ข้อใดไม่ใช่ข้อมูลอนุกรมเวลา (Time Series)

คำตอบ: ค่าไฟฟ้าของห้องทุกห้องในคอนโดตอนเดือนมกราคม 2020

คำอธิบาย: เป็นข้อมูลตัดขวาง (Cross-sectional) ณ จุดเวลาเดียว ไม่ได้ดูการเปลี่ยนแปลงตามลำดับเวลาของหน่วยเดิม

ข้อที่ 2

โจทย์: ข้อใดไม่ถูกต้องเกี่ยวกับข้อมูล time series

คำตอบ: ข้อมูล time series ต้องเก็บในช่วงเวลาที่ห่างเท่า ๆ กัน

คำอธิบาย: ไม่จำเป็นเสมอไป ข้อมูลบางประเภทเช่นราคาหุ้นรายธุรกรรมอาจบันทึกในช่วงเวลาที่ไม่สม่ำเสมอได้

ข้อที่ 3

โจทย์: ข้อมูลจำนวนผู้ป่วยใหม่รายวันในประเทศต่างๆ ดังรูป เป็นข้อมูลประเภทใด

ลักษณะรูปภาพ: ภาพแสดงกราฟเส้นจำนวนผู้ป่วย COVID-19 หลายเส้นตามแต่ละประเทศในช่วงเวลาเดียวกัน

คำตอบ: เป็น time series แบบ multivariate

คำอธิบาย: เนื่องจากมีการพิจารณาหลายตัวแปร (หลายประเทศ) ที่เปลี่ยนแปลงไปตามลำดับเวลาเดียวกัน

ข้อที่ 4

โจทย์: ลักษณะใดที่บ่งบอกว่าข้อมูลเป็น Additive time series

ลักษณะรูปภาพ: ภาพแสดงกราฟความต้องการใช้ไฟฟ้า (Electricity Demand) ที่มีความผันผวนคงที่ตลอดช่วงเวลา

คำตอบ: Additive

คำอธิบาย: ใน Additive model ขนาดของความผันผวน (Seasonal variation) จะคงที่ ไม่แปรผันตามระดับแนวโน้มหลัก

ข้อที่ 5

โจทย์: จากกราฟ A, B, C จงระบุส่วนประกอบจากการ Decompose

ลักษณะรูปภาพ: ภาพแสดงองค์ประกอบ 3 ส่วน ได้แก่ กราฟ A (คลื่นซ้ำๆ), กราฟ B (ลุ่ม), กราฟ C (เส้นโค้งทิศทาง)

คำตอบ: A – seasonal, B – residual, C – trend

คำอธิบาย: Seasonal แสดงรูปแบบซ้ำๆ, Trend แสดงทิศทางระยะยาว และ Residual แสดงค่าที่เหลือที่เป็นสัญญาณรบกวน

ข้อที่ 6

โจทย์: ข้อใดไม่ถูกต้องเกี่ยวกับ time series decomposition

คำตอบ: ข้อมูล time series จะประกอบด้วยสามส่วนเสมอ (และ Trend บ่งบอกความสัมพันธ์ปัจจุบันกับอดีต)

คำอธิบาย: ในทางวิชาการอาจมีส่วนประกอบอื่นเช่น Cyclical และ Trend บอกแค่ทิศทาง ไม่ได้บอกความสัมพันธ์เชิงโครงสร้างย้อนหลัง

ข้อที่ 7

โจทย์: ข้อใดกล่าวถูกต้องที่สุดเกี่ยวกับ stationary property ของ time series

คำตอบ: ถ้าแบ่งข้อมูล stationary เป็นสองส่วน ค่า variance ของครึ่งแรกจะมีค่าเท่ากับของครึ่งหลัง

คำอธิบาย: ตามนิยามของ Stationary ความแปรปรวน (Variance) ต้องคงที่ตลอดช่วงเวลา

ข้อที่ 8

โจทย์: หลักฐานใดใช้สนับสนุนว่าข้อมูลเป็น stationary time series

คำตอบ: A, C, D, F (Running mean คงที่, ไม่มี seasonal, ADF p-value ต่ำ, Autocorrelation ลดลงเร็ว)

คำอธิบาย: เป็นคุณสมบัติพื้นฐานและผลการทดสอบทางสถิติที่ยืนยันความคงที่ของข้อมูล

ข้อที่ 10

โจทย์: ถ้าจะแปลงข้อมูลให้กลายเป็น stationary จะต้องทำกระบวนการใดบ้าง

คำตอบ: A, B, C (ทำ Differencing ลด trend/seasonal และทำ log transformation)

คำอธิบาย: เพื่อจัดการทั้งความแปรปรวนที่ไม่คงที่, อิทธิพลของฤดูกาล และแนวโน้มของข้อมูล

ข้อที่ 11

โจทย์: ข้อใดไม่ใช่ประโยชน์ของการ smoothing

คำตอบ: สามารถนำมาใช้ทำนายอนาคตได้

คำอธิบาย: Smoothing เป็นการจัดการข้อมูลอดีตเพื่อให้มองเห็น Pattern ชัดขึ้น แต่ไม่มีคุณสมบัติในการพยากรณ์อนาคตในตัวเอง

ข้อที่ 12

โจทย์: หากข้อมูลมี Seasonality แต่ไม่มี Trend ควรใช้ smoothing ประเภทใดดีที่สุด

คำตอบ: Triple Exponential Smoothing (Holt-Winters)

คำอธิบาย: แม้จะระบุว่าไม่มี Trend แต่ในตระกูลนี้ มีเพียง Triple Smoothing เท่านั้นที่รองรับองค์ประกอบฤดูกาล (Seasonality)

ข้อที่ 13

โจทย์: ข้อใดเป็นเหตุผลหลักที่จะใช้ moving average แทน exponential moving average

คำตอบ: เมื่อต้องการให้น้ำหนักของข้อมูลในการเฉลี่ยเท่า ๆ กัน

คำอธิบาย: Simple Moving Average ให้น้ำหนักทุกจุดเท่ากัน ต่างจาก EMA ที่ให้น้ำหนักข้อมูลใหม่มากกว่า

ข้อที่ 14

โจทย์: SARIMA, ARIMA, ARMA จะทำงานได้ดีบนข้อมูลลักษณะใด

คำตอบ: ข้อมูล Stationary และ ลักษณะของข้อมูลในอดีตบ่งบอกถึงลักษณะข้อมูลในอนาคต

คำอธิบาย: ต้องมีความคงที่ทางสถิติและมีความสัมพันธ์กันเอง (Autocorrelation) เพื่อให้โมเดลเรียนรู้ได้

ข้อที่ 15

โจทย์: ข้อใดไม่ถูกต้องเกี่ยวกับทำนายบนข้อมูล time series

คำตอบ: โมเดล SARIMA จะได้ผลดีที่สุด เพราะสามารถรับมือข้อมูลได้ทุกประเภท

คำอธิบาย: ไม่มีโมเดลเดียวที่เก่งที่สุด SARIMA เป็นเชิงเส้น หากข้อมูลซับซ้อนมาก Machine Learning อาจทำได้ดีกว่า

ข้อที่ 16

โจทย์: ข้อใดไม่ถูกต้องเกี่ยวกับโมเดล ARMA, ARIMA และ SARIMA

คำตอบ: เวลาใช้โมเดลให้เลือกค่า p q ที่ทำให้ได้ค่า error น้อยที่สุดใน training data

คำอธิบาย: การเลือกตาม training error อย่างเดียวจะนำไปสู่ Overfitting ควรใช้เกณฑ์เช่น AIC/BIC

ข้อที่ 17

โจทย์: ข้อใดถูกต้องที่สุดเกี่ยวกับ confidence interval

คำตอบ: Confidence interval จะกว้างขึ้นตาม คำอธิบาย: เพื่อความมั่นใจที่สูงขึ้น ต้องขยายช่วงให้กว้างขึ้นเพื่อดักจับค่าที่แท้จริงได้ครอบคลุมมากขึ้น

ข้อที่ 18

โจทย์: ข้อใดไม่ถูกต้องเกี่ยวกับ Facebook Prophet

คำตอบ: สามารถทำทุกอย่างที่ SARIMA ทำได้

คำอธิบาย: สองโมเดลมีปรัชญาต่างกัน Prophet เป็น Additive Curve Fitting ส่วน SARIMA เป็น Stochastic Process

ข้อที่ 19

โจทย์: กรณีใดที่ควรใช้ supervised learning แทน time series modeling

คำตอบ: มีข้อมูลน้อย เช่น มีรอบ seasonal เพียงหนึ่งรอบ

คำอธิบาย: โมเดล Time Series ต้องการข้อมูลหลายรอบเพื่อแยก Trend/Seasonal หากน้อยไปควรใช้ Feature Engineering ใน Supervised แทน

ข้อที่ 20

โจทย์: ข้อใดไม่ถูกต้องเกี่ยวกับการโมเดล time series

คำตอบ: ควรใช้โมเดลที่ซับซ้อนที่สุดเพื่อจะได้รับมือกับข้อมูลทุกรูปแบบ

คำอธิบาย: ขัดกับหลัก Occam's Razor โมเดลซับซ้อนเกินไปมัก Overfit และอธิบายได้ยาก

ข้อที่ 21

โจทย์: ข้อใดไม่ถูกต้องเกี่ยวกับการประยุกต์ใช้ time series modeling

คำตอบ: สามารถนำ Confidence interval ของการทำนายใช้บอกจุดสูงสุดและต่ำสุดของความเป็นไปได้ของข้อมูลได้

คำอธิบาย: ต้องใช้ Prediction Interval (PI) ไม่ใช่ Confidence Interval (CI) เนื่องจาก PI ครอบคลุมความผันผวนของข้อมูลจริงด้วย